Atividade prática

Três bases, três problemas: analisar, escolher o algoritmo e resolver

Você tem **três bases de dados** (arquivos `.csv`). Para cada uma, o seu trabalho tem quatro partes: **analisar** a base, **decidir** o tipo de problema, **escolher** os algoritmos candidatos e **resolver** na ordem dos quadros *Passo a passo* (classificação, regressão ou agrupamento). O enunciado não diz qual algoritmo usar: a escolha e a justificativa é definido por voce.

Arquivo	Contexto	Pergunta do negócio
`base1_classificacao_churn.csv`	clientes de uma operadora de internet	quem vai cancelar o serviço?
`base2_regressao_imoveis.csv`	imóveis à venda em uma cidade média	quanto vale um imóvel com estas características?
`base3_agrupamento_clientes.csv`	clientes cadastrados de uma rede de lojas	existem perfis de cliente? quantos e como são?

Antes de programar, use o fluxograma *Tenho um TARGET (y)?* para decidir o tipo de cada problema. Uma base pode não ser o que o nome do arquivo sugere: confira.

1. Regras gerais

- Linguagem Python com `pandas` e `scikit-learn`. Pode ser um notebook (`.ipynb`) ou um script (`.py`) por base, que rode do início ao fim sem erro.
- Siga a **sequência dos quadros**: ler, tratar, separar X e y (quando houver y), treino e teste, Pipeline, K-Fold, busca de hiperparâmetros, melhor modelo, teste uma única vez, avaliação.
- **Compare pelo menos três algoritmos** por base (nos problemas supervisionados, mais um baseline com `Dummy`). Justifique em uma frase por que cada candidato faz sentido para os dados.
- Tudo que aprende com os dados (imputação, padronização, codificação) fica **dentro do Pipeline**. O teste só aparece no passo 9, uma vez.
- Use `random_state=42` em tudo para o seu resultado poder ser conferido.
- Escreva as respostas das **perguntas de análise** como comentários ou células de texto, em frases curtas.

2. Base 1: cancelamento de clientes

Cada linha é um cliente. A coluna `cancelou` vale 1 se o cliente cancelou o serviço nos 6 meses seguintes e 0 caso contrário.

Coluna	Descrição
`id_cliente`	identificador do cliente
`idade`	idade em anos
`tempo_cliente_meses`	meses desde a contratação
`plano`	basico, intermediario ou premium
`mensalidade`	valor mensal em reais
`forma_pagamento`	cartao, boleto ou debito_automatico
`chamados_suporte_6m`	chamados abertos nos últimos 6 meses
`uso_dados_gb`	consumo mensal médio, em GB
`atrasos_pagamento_12m`	faturas pagas com atraso nos últimos 12 meses
`cancelou`	alvo: 1 = cancelou, 0 = permaneceu

Perguntas de análise

- Qual é a proporção de cada classe? Um modelo que sempre responde "não cancela" seria bom? Que métrica você usará e por quê?
- Há valores ausentes, linhas repetidas ou colunas que não deveriam entrar no modelo? O que você fez com cada uma?
- Quais colunas são numéricas e quais são texto? O que o algoritmo exige de cada tipo?

Tarefa

1. Resolva o problema seguindo o quadro de **Classificação**.
2. Apresente a **matriz de confusão** e o `classification_report` do melhor modelo no teste.
3. Responda: qual tipo de erro é mais caro para a operadora (deixar um cliente cancelar sem aviso ou fazer oferta a quem ficaria)? O seu modelo está equilibrado para isso?

3. Base 2: preço de imóveis

Cada linha é um imóvel anunciado. A coluna `preco_venda` é o valor de venda em reais.

Coluna	Descrição
`area_m2`	área útil em metros quadrados
`quartos`, `banheiros`, `vagas_garagem`	contagens
`idade_imovel_anos`	anos desde a construção
`distancia_centro_km`	distância até o centro, em km
`bairro`	Centro, Jardim Europa, Vila Nova, Industrial ou Periferia
`condominio_mensal`	valor do condomínio, em reais por mês
`preco_venda`	alvo: preço de venda, em reais

Perguntas de análise

- Olhe `describe()` de cada coluna numérica. Algum valor é fisicamente impossível ou parece erro de digitação? Como você decidiu tratá-lo?
- Qual é a ordem de grandeza do alvo? Que algoritmos podem ter dificuldade com ela?
- Qual seria o erro de um modelo que sempre prevê a média? Use-o como piso (`DummyRegressor`).

Tarefa

1. Resolva o problema seguindo o quadro de **Regressão**, com `KFold(shuffle=True)` e `neg_root_mean_squared_error`.
2. Reporte **MAE, RMSE e R^2** do melhor modelo no teste, em reais, e compare com o baseline.
3. Desenhe o gráfico de **resíduos** (real contra previsto) e diga, em duas frases, se há padrão que o modelo não capturou.

4. Base 3: perfis de clientes

Cada linha é um cliente cadastrado. **Não existe coluna alvo**: a empresa quer descobrir perfis para campanhas diferentes.

Coluna	Descrição
`id_cliente`	identificador
`idade`	anos
`renda_mensal_mil`	renda declarada, em milhares de reais
`gasto_mensal`	gasto médio na rede, em reais
`visitas_mes`	visitas às lojas por mês
`ticket_medio`	valor médio por compra, em reais
`tempo_cadastro_anos`	anos de cadastro
`avaliacao_app`	nota média que o cliente deu ao aplicativo (1 a 5)

Perguntas de análise

- Compare as escalas das colunas (`describe()`). O que acontece com a distância entre dois clientes se você não tratar isso?
- Existem valores muito fora do padrão? São plausíveis ou erro?
- Todas as colunas devem entrar no agrupamento? Calcule a correlação de `avaliacao_app` com as demais e decida.

Tarefa

1. Resolva seguindo o quadro de **Agrupamento**: varra K, calcule inércia, silhueta, Davies-Bouldin e Calinski-Harabasz, e **justifique o K escolhido** com mais de uma métrica.
2. Compare o K-Means com pelo menos mais um método (Hierárquico, DBSCAN ou Fuzzy C-Means).
3. **Interprete** os grupos: tabela com a média de cada coluna por grupo, um nome para cada perfil e uma ação de marketing diferente para cada um.
4. Reduza com **PCA** a duas dimensões e desenhe os grupos. Informe a variância explicada.

5. O que entregar e como será avaliado

Para cada base: o notebook ou script e a página de respostas (análise, justificativas e conclusões). Cada base vale 10 pontos.

Critério	Base 1 e 2	Base 3
Análise da base e justificativa do tipo de problema	2,0	2,0
Tratamento dos dados (sem vazamento, dentro do Pipeline)	2,0	2,0
Escolha e justificativa dos algoritmos candidatos	1,5	1,5
Validação (K-Fold e busca) / varredura de K e métricas	2,0	2,0
Avaliação com a métrica adequada e baseline / interpretação dos perfis	1,5	1,5
Conclusão e visualização	1,0	1,0
Total	10,0	10,0