

Aula 2 — Parte 1

Notações, Dados e o Fechamento do Primeiro Classificador

Objetivos desta sessão

1. Retomar a divisão treino/teste feita na sessão passada e **completar o ciclo do K-NN**: treinar, prever, avaliar e interpretar — etapa que não coube no tempo da última aula.
2. Observar o efeito do hiperparâmetro **k** e da **escala dos atributos** sobre o desempenho do K-NN.
3. Formalizar a notação usada no restante do semestre: **exemplo, atributo, rótulo, matriz X, vetor y**.
4. Traduzir uma necessidade em tarefa computacional: identificar X, y e a unidade de análise em um problema novo.
5. Registrar resultados e escrever interpretações — habilidade cobrada em todos os trabalhos do semestre.

1. Retomada: onde paramos na Aula 1

Na sessão de 04/08 você fez a parte que antecede todo treinamento, você aprendeu a fazer a limpeza e preparar a base de dados para o treinamento.

2. Fechando o K-NN: treinar, prever, avaliar

Retome X_treino, X_teste, y_treino, y_teste da sessão passada (ou rode novamente a divisão — o código está no início de lab02_parte1_demo.py). O K-NN não constrói equação nem árvore: ele guarda os exemplos de treino e, para classificar uma flor nova, encontra as k flores de treino mais próximas por distância euclidiana e devolve a espécie mais frequente entre elas.

```
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

modelo = KNeighborsClassifier(n_neighbors=5)      # k = 5 vizinhos
modelo.fit(X_treino, y_treino)                  # "treina": memoriza os exemplos

y_previsto = modelo.predict(X_teste)            # opina sobre dados nunca vistos
print("acurácia:", round(accuracy_score(y_teste, y_previsto), 4))
print(confusion_matrix(y_teste, y_previsto))
```

Trecho 1 — o ciclo fit / predict / avaliar. Essa é a mesma API para todo modelo do semestre.

2.1 Lendo a matriz de confusão

A acurácia é um número só e esconde onde o modelo erra. Na matriz de confusão, as linhas são a verdade e as colunas a previsão; a diagonal são os acertos. Com k=5 e random_state=42 você deve obter 44 acertos em 45 flores (97,8%), com o único erro entre versicolor e virginica — exatamente a fronteira que a inspeção da Aula 1 já indicava sobreposta.

Vale mais que o número

Escrever "acurácia de 97,8%" vale pouco em um relatório. Escrever "97,8%, com o único erro na fronteira virginica/versicolor, que a inspeção dos dados já indicava sobreposta" mostra que você entendeu o problema — e é isso que se cobra na interpretação.

2.2 O efeito de k

k é um hiperparâmetro: você escolhe antes do treino, não é aprendido dos dados. Com k=1 o modelo copia o vizinho mais próximo (que, no treino, é ele mesmo) e sobreajusta: acerta 100% do treino e menos do teste. Com k muito grande, a vizinhança consultada é tão ampla que o modelo tende a prever sempre a classe majoritária: subajuste.

```
for k in [1, 3, 5, 7, 9, 11, 15, 21, 31, 51]:
    m = KNeighborsClassifier(n_neighbors=k).fit(X_treino, y_treino)
    ac_treino = accuracy_score(y_treino, m.predict(X_treino))
    ac_teste = accuracy_score(y_teste, m.predict(X_teste))
    print(f"k={k}>3}  treino={ac_treino:.3f}  teste={ac_teste:.3f}")
```

Trecho 2 — varredura de k. Existe uma faixa intermediária boa, e ela se descobre testando, não adivinhando.

Cuidado metodológico

Escolher o k que maximiza a acurácia olhando o conjunto de teste contamina esse conjunto: ele deixa de ser "dato nunca visto". O procedimento correto usa validação ou validação cruzada para escolher k, reservando o teste para uma única medida final. Formalizamos isso na Aula 8.

2.3 O efeito da escala

O K-NN decide por distância, então a unidade de cada atributo importa. Multiplicar uma única coluna por 1.000 (simulando uma unidade diferente) faz a acurácia despencar, porque a distância euclidiana passa a ser dominada por essa coluna. Um StandardScaler dentro de um Pipeline devolve peso comparável a cada atributo — e é fundamental que a padronização aconteça só dentro do pipeline, aprendida apenas no treino.

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler

# CORRETO: o scaler aprende media e desvio SO no treino, dentro do pipeline
pipe = make_pipeline(StandardScaler(), KNeighborsClassifier(n_neighbors=5))
pipe.fit(X_treino, y_treino)

# ERRADO: ajustar o scaler em X inteiro vaza informacao do teste para o treino
# X_todo = StandardScaler().fit_transform(X)  # <- nao faca isso (Aula 4: data leakage)
```

Trecho 3 — Pipeline não é organização por organização: é o que impede o vazamento de dados do teste para o treino.

3. Notação formal: de exemplos soltos a X e y

Você já usou X, y, treino e teste na prática. Agora formalizamos esse vocabulário, porque ele será a linguagem comum do restante do semestre — inclusive nas provas.

Termo	Significado	No K-NN que você treinou hoje
Exemplo (amostra)	Uma unidade de observação; em geral, uma linha da tabela.	Uma flor medida.
Atributo (feature)	Uma variável de entrada que descreve o exemplo; uma coluna.	Comprimento da pétala, largura da sépala.
Rótulo (alvo, y)	O que se quer prever; existe no aprendizado supervisionado.	A espécie: setosa, versicolor ou virginica.
Matriz X e vetor y	X reúne os atributos (n exemplos × d atributos); y reúne os rótulos.	X_treino tem forma (105, 4); y_treino tem 105 valores.
Hiperparâmetro	Escolhido por quem modela, antes do treino; não é aprendido.	k, o número de vizinhos consultados.

Termo	Significado	No K-NN que você treinou hoje
Parâmetro / modelo treinado	O que o algoritmo ajusta durante o fit.	Os 105 exemplos memorizados pelo K-NN.

3.1 Da pergunta ao dataset

Formular um problema de aprendizado de máquina significa transformar uma necessidade em tarefa computacional, antes de cogitar qualquer algoritmo. Três perguntas guiam essa tradução:

- Qual é a **unidade de análise**? Isto é: o que vira uma linha da tabela (um exemplo)?
- Quais **atributos** estarão disponíveis para descrever cada exemplo — e eles existem de fato, ou seriam desejáveis apenas na teoria?
- Existe um **rótulo** conhecido a prever (supervisionado) ou o objetivo é descrever estrutura sem rótulo (não supervisionado)?

Exemplo aplicado ao câmpus: suponha que a coordenação queira antecipar risco de evasão. A unidade de análise é o aluno-matrícula; atributos possíveis incluem frequência, notas parciais e tempo médio de resposta às atividades; o rótulo, se houver histórico, é evadiu/não evadiu. Note que a formulação já expõe um risco: se a base histórica for pequena ou enviesada por campus, o modelo aprende o viés, não o fenômeno.

3.2 Treino, validação e teste — os papéis

Treino ajusta os parâmetros do modelo. Validação ajuda a escolher configurações e hiperparâmetros (como o k da Seção 2.2) sem tocar no teste. Teste estima o desempenho final, uma única vez, sobre dados que nunca influenciaram nenhuma decisão de modelagem. Misturar esses três papéis — por exemplo, escolher k olhando a acurácia de teste — produz resultados otimistas e não verificáveis.

Por que isso importa desde já

Hoje você usou apenas treino/teste porque o Iris é pequeno e o objetivo era ilustrar o ciclo completo. A partir da Aula 8 (validação cruzada) o padrão profissional passa a incluir validação — mas o vocabulário e o motivo já ficam fixados aqui.

O que guardar desta sessão

- O K-NN decide por vizinhança e distância: sensível a **k** (hiperparâmetro) e à **escala** dos atributos.
- X é a matriz de atributos ($n \times d$); y é o vetor de rótulos (n). Essa notação vale para todo modelo do semestre.
- Formular um problema é definir unidade de análise, atributos disponíveis e rótulo **antes** de escolher algoritmo.
- Treino, validação e teste têm papéis distintos; usar o teste para decidir configuração invalida a avaliação.

Exercícios — Aula 2, Parte 1

Use sempre `random_state=42`.

Exercício 1 — Fechamento do K-NN

Usando a mesma divisão treino/teste da Aula 1 (ou refazendo com `random_state=42`), treine um `KNeighborsClassifier(n_neighbors=5)`, imprima a acurácia, a matriz de confusão e o `classification_report`. No relatório, indique entre quais classes ocorreram os erros e proponha uma explicação a partir das médias por espécie.

Exercício 2 — Efeito de k e da escala

Repita a varredura de k do Trecho 2 e o experimento de escala do Trecho 3. No relatório: (a) qual k obteve a melhor acurácia de teste? (b) por que escolher k olhando o teste é metodologicamente problemático? (c) por que o K-NN é sensível à escala, e por que o Pipeline evita o vazamento de dados?

Exercício 3 — Vocabulário

Para o experimento do Exercício 1, identifique explicitamente: (a) a unidade de análise; (b) o formato de `X_treino` e `y_treino` (shape); (c) um exemplo de atributo e um exemplo de rótulo; (d) o hiperparâmetro usado e seu valor.

Exercício 4 — Formulação de um problema novo (2,0)

Escolha um problema do seu cotidiano ou do câmpus (diferente do exemplo de evasão desta apostila). Descreva: (a) a unidade de análise; (b) três atributos disponíveis; (c) o rótulo, se houver; (d) se é um problema supervisionado ou não; (e) um risco de a formulação estar errada.

Exercício 5 — Treino, validação e teste (1,0)

Explique com suas palavras por que escolher um hiperparâmetro observando a acurácia no conjunto de teste invalida a avaliação final, e descreva em uma frase o que um conjunto de validação resolveria.