

Do problema real a X e y

Guia explicativo da atividade curta com NumPy e pandas

Problema	Prever atraso na próxima atividade
Unidade de análise	Um aluno em uma semana
Atributos	Frequência, média e entregas
Rótulo (y)	Atrasou: 0 = não, 1 = sim

Objetivos

Representar uma tabela como array NumPy; converter o array em DataFrame; reconhecer exemplos, atributos e rótulo; separar corretamente a matriz X e o vetor y; e avaliar criticamente uma formulação de aprendizado supervisionado.

1. Da situação real para uma tabela

Antes de escolher um algoritmo, é preciso definir o que cada linha representa. Nesta atividade, uma linha representa um aluno observado durante uma semana. Essa definição é chamada de unidade de análise.

Os valores são organizados inicialmente em um array NumPy. O array é eficiente para cálculos, mas não guarda nomes de colunas. Por isso, o passo seguinte converte os dados para um DataFrame pandas.

```
dados = np.array([...])
df = pd.DataFrame(dados, columns=colunas)
```

2. Significado de X e y

X contém as informações disponíveis no momento da previsão. Cada linha é um exemplo e cada coluna é um atributo. y contém a resposta histórica que o modelo tentará aprender a prever.

Objeto	Conteúdo	Dimensão esperada
X	frequência, média e atividades entregues	8 linhas x 3 colunas
y	atrasou ou não atrasou	8 valores

```
X = df[["frequencia", "media_parcial", "atividades_entregues"]]
y = df["atrasou_proxima_atividade"]
```

A coluna que contém a resposta não deve permanecer em X. Caso isso aconteça, o modelo recebe a própria resposta como entrada, produzindo vazamento de dados e uma avaliação enganosa.

3. Roteiro da atividade

1. Execute as importações e a criação do array.
2. Inspecione o formato e a primeira linha.
3. Converta os dados para DataFrame e verifique tipos e valores ausentes.
4. Crie X e y e confira seus formatos.
5. Faça o gráfico da distribuição das classes.
6. Responda às perguntas de interpretação.
7. Se houver tempo, realize o desafio opcional.

4. Resultados esperados

O conjunto possui 8 exemplos. X deve possuir 3 atributos e formato (8, 3); y deve possuir 8 rótulos e formato (8,). Há 4 exemplos de cada classe, portanto a pequena base está balanceada.

O problema é supervisionado porque existe um rótulo histórico conhecido para cada exemplo. Ainda assim, os dados são apenas didáticos: oito registros são insuficientes para treinar ou validar um modelo confiável.

5. Discussão crítica

Uma formulação pode estar errada mesmo quando o código funciona. Frequência e notas podem refletir situações socioeconômicas, dificuldades de acesso ou critérios diferentes entre disciplinas. Antes de usar previsões para tomar decisões, seria necessário ampliar a base, verificar vieses, proteger dados pessoais e definir uma intervenção pedagógica que apoie - e não puna - o estudante.

Critérios de conclusão

A atividade está concluída quando o aluno consegue explicar a unidade de análise, diferenciar atributo e rótulo, mostrar as dimensões de X e y e justificar por que a coluna-alvo deve ser retirada de X.