



O Blueprint do Aprendizado Supervisionado

Representação de Dados,
Formulação X/y e a Mecânica do K-NN



0 Ciclo de Vida do Aprendizado



0 código muda. 0 framework matemático permanece.

0 Desafio Tabular: Dataset Wine

Data Specification Card	
Unidade de Análise:	Amostra de vinho italiano
Amostras (n):	178 linhas
Atributos (d):	13 medidas químicas (álcool, ácido málico, magnésio, prolina)
Classes (y):	3 cultivares distintos de origem



ALERTA DE ESCALA: Magnésio (~70 a 160) vs. Prolina (~280 a 1680). Disparidade extrema detectada.


Inspeção: O Dicionário de Dados

```
dicionario = pd.DataFrame({  
    'atributo': X.columns,  
    'tipo': [str(t) for t in X.dtypes],  
    'exemplo': [X[c].iloc[0] for c in X.columns],  
})
```

Prática
profissional:
olhar antes
de treinar.

Atributo	Tipo	Exemplo
alcohol	float64	14.23
malic_acid	float64	1.71
ash	float64	2.43

A Anatomia Universal de um Dataset




Esta separação explícita não é uma peculiaridade de uma biblioteca. É a formulação matemática inequívoca para qualquer problema de aprendizado supervisionado.

A Armadilha Euclidiana


Por que o K-NN falha com dados não padronizados

Sem Padronização



A distância euclidiana é dominada pela Prolina. O algoritmo fica funcionalmente cego para outras variáveis.

Com StandardScaler



As escalas são equalizadas. Todos os 13 atributos ganham voz igual na decisão matemática.

Consolidando a Mecânica: K-NN em Ação

0 K-NN Cego

```
KNeighborsClassifier(n_neighbors=5)
```



Acurácia: ~70%

0 K-NN Ajustado

```
make_pipeline(StandardScaler(),  
KNeighborsClassifier(n_neighbors=5))
```



Acurácia: ~94%

Diferente do dataset Iris, no Wine a padronização deixa de ser opcional e torna-se o comportamento padrão necessário para o algoritmo de distância.

0 Teste de Generalização

```
load_breast_cancer(as_frame=True)
```

Unidade de Análise: Biópsia de tumor

Amostras (n): 569 linhas

Atributos (d): 30 medidas celulares

Domínio: Oncologia clínica

Se o nosso framework é robusto, o processo matemático de inspecionar, formular X/y e avaliar com K-NN funcionará exatamente da mesma forma neste novo domínio.

Matriz Diagnóstica de Datasets

	Iris	Wine	Breast Cancer
Unidade de Análise	Uma flor medida	Uma amostra de vinho	Célula tumoral
Amostras (n)	150	178	569
Atributos (d)	4 (Mesma unidade)	13 (Unidades díspares)	30 (Múltiplas escalas)
Rótulo (y)	Espécie	Cultivar	Diagnóstico
Padronização Necessária?	Não essencial	Essencial	Essencial

Princípios Universais do Aprendizado Supervisionado

1. A Separação é Matemática

O comando **drop** não é um truque de código. A divisão estrita entre o espaço de espaço de características (**X**) e o alvo (**y**) é a fundação de toda modelagem.

2. Olhar Antes de Treinar

Dicionários de dados não são burocracia. Eles são a linha de frente de engenharia para evitar falhas silenciosas na ingestão de dados.

3. Escalas Desiguais são a Regra

Datasets perfeitos como o Iris são exceções didáticas. No mundo real, padronizar atributos para algoritmos baseados em distância é um imperativo.