

Aula 3 — Parte 1

Paradigmas de Aprendizado: Supervisionado, Não Supervisionado e por Reforço

Data	Segunda-feira, 17/08/2026 — sessão 5 de 36
Unidade da ementa	2. Paradigmas de aprendizagem
Local	Laboratório de Informática (cada aluno em uma máquina)
Arquivos	lab03_parte1_demo.py • lab03_parte1_exercicios.py
Entrega	lab03_parte1_exercicios.py preenchido e executado + relatório de conclusão

Objetivos desta sessão

1. Diferenciar os paradigmas de aprendizagem pelo tipo de sinal disponível: rótulo, recompensa ou nenhum dos dois.
2. Situar **classificação** e **regressão** como duas variantes do aprendizagem supervisionado.
3. Reconhecer o **agrupamento** como a tarefa não supervisionada mais comum, e identificar quando ela é a resposta certa.
4. Descrever o ciclo agente–ambiente–ação–recompensa do **aprendizado por reforço**.
5. Observar, na prática, o que muda quando um algoritmo aprende **sem ver o rótulo**.

1. Retomada: o que já sabemos fazer

Nas duas primeiras semanas você formulou problemas em X e y, treinou e avaliou um K-NN em dois datasets diferentes (Iris e Wine) e viu por que a escala dos atributos importa para algoritmos baseados em distância. Em todos os casos havia um rótulo y conhecido, usado tanto para treinar quanto para avaliar. Hoje perguntamos: o que fazemos quando esse rótulo não existe?

2. A pergunta que decide o paradigma

Antes de escolher um algoritmo, pergunte: existe um rótulo conhecido para cada exemplo? Existe, em vez disso, um sinal de recompensa que chega ao longo do tempo, conforme um agente age? A resposta a essas duas perguntas já classifica o problema.

Paradigma	Sinal disponível	Objetivo	Exemplo
Supervisionado	rótulo y conhecido para cada exemplo	prever y em exemplos novos	prever a espécie de uma flor
Não supervisionado	nenhum rótulo	descobrir estrutura nos dados	agrupar clientes por padrão de compra
Semi-supervisionado	rótulo em poucos exemplos, a maioria sem	aproveitar os poucos rótulos e a estrutura dos dados sem rótulo	classificar e-mails com poucos exemplos marcados

Paradigma	Sinal disponível	Objetivo	Exemplo
Por reforço	recompensa numérica após cada ação, sem rótulo direto	aprender uma política de ações que maximize a recompensa	um agente aprendendo a jogar

3. Aprendizado supervisionado: duas variantes

Você já pratica aprendizado supervisionado desde a Aula 1: o K-NN aprende com pares (X, y) e prevê y para exemplos novos. A variante depende do tipo de y :

- **Classificação** — y é uma categoria (espécie, cultivar, spam/não-spam). É o que você fez até aqui. Detalhamos na Aula 7.
- **Regressão** — y é um número contínuo (preço, temperatura, tempo de entrega). Ainda não praticamos; chega na Aula 6.

A pergunta que separa os dois: se eu embaralhar as categorias, a ordem importa? Em classificação, não — "setosa" não é "menor" que "virginica". Em regressão, sim — R\$ 300.000 é maior que R\$ 200.000, e essa relação de ordem é parte do que o modelo aprende.

4. Aprendizado não supervisionado

Sem rótulo, o objetivo deixa de ser prever e passa a ser descrever estrutura. As tarefas mais comuns:

- **Agrupamento (clustering)** — separar exemplos em grupos por similaridade, sem que os grupos sejam definidos de antemão. Tema das Aulas 9 e 10.
- **Redução de dimensionalidade** — resumir muitos atributos em poucos, preservando o essencial da informação. Aparece na Aula 4 e na Aula 11.
- **Deteção de anomalias** — encontrar exemplos que destoam do padrão geral, útil em fraude e falhas de equipamento.

O erro conceitual mais comum

Dizer que "não supervisionado" significa "sem correção" ou "pior que supervisionado" está errado. Significa apenas que não há rótulo disponível no momento do treino — o que é a situação real na maior parte dos dados do mundo, que não vêm pré-rotulados.

5. Aprendizado semi-supervisionado (breve)

Situação intermediária e comum na prática: você tem poucos exemplos rotulados (rotular é caro — exige um especialista, por exemplo) e muitos exemplos sem rótulo. O modelo usa os poucos rótulos como âncora e a estrutura dos dados não rotulados para generalizar melhor do que usaria só com os poucos rótulos. Não aprofundamos neste semestre, mas vale saber que a fronteira entre supervisionado e não supervisionado não é rígida.

6. Aprendizado por reforço

Aqui não há um dataset fixo de exemplos rotulados. Um **agente** interage com um **ambiente**: a cada passo, observa um **estado**, escolhe uma **ação**, e recebe uma **recompensa** — um número que indica se aquela ação foi boa ou ruim naquele contexto. O objetivo é aprender uma **política**: uma regra de qual ação tomar em cada estado, que maximize a recompensa acumulada ao longo do tempo.

Termo	Significado	Exemplo: agente jogando um jogo
Agente	quem decide e age	o programa que joga

Termo	Significado	Exemplo: agente jogando um jogo
Ambiente	tudo que responde às ações do agente	o tabuleiro e as regras do jogo
Estado	a situação atual observada pelo agente	a posição das peças agora
Ação	o que o agente pode fazer	mover uma peça
Recompensa	sinal numérico após a ação	+1 se vencer, -1 se perder, 0 no meio do jogo
Política	a regra aprendida de ação por estado	a estratégia final do agente

Você já viu um exemplo na Aula 1: Samuel treinando um programa de damas contra si mesmo em 1959, e AlphaGo vencendo Lee Sedol em 2016. Não implementaremos aprendizado por reforço neste semestre — o objetivo aqui é reconhecer o paradigma quando ele aparecer.

7. Demonstração guiada: o K-Means no Iris

K-Means é ao agrupamento o que o K-NN é à classificação: o algoritmo não supervisionado mais simples de explicar. Você escolhe k (agora, o número de grupos, não de vizinhos) e o algoritmo posiciona k centros, atribui cada exemplo ao centro mais próximo e ajusta os centros — sem nunca olhar para y .

```
from sklearn.datasets import load_iris
from sklearn.cluster import KMeans

dados = load_iris()
X = dados.data          # note: y NAO entra aqui

kmeans = KMeans(n_clusters=3, random_state=42, n_init=10)
clusters = kmeans.fit_predict(X)  # agrupa usando so os atributos

print(clusters[:10])        # rotulos de GRUPO, nao de especie
```

Trecho 1 — fit_predict aprende a estrutura e já devolve o grupo de cada exemplo. Repare: em nenhum momento y aparece.

Só para fins didáticos — porque o Iris tem y conhecido — podemos comparar os grupos encontrados com as espécies reais:

```
import pandas as pd
from sklearn.metrics import adjusted_rand_score

y = dados.target
print(pd.crosstab(y, clusters, rownames=["real"], colnames=["cluster"]))
print("ARI:", adjusted_rand_score(y, clusters))
```

Trecho 2 — comparação só possível porque este é um dataset didático com y conhecido. Em um problema não supervisionado real, essa comparação não existe.

Leitura do resultado

O K-Means separa setosa perfeitamente (as 50 flores caem em um único grupo, sem nenhuma outra espécie misturada) — mesma fronteira nítida que o K-NN já explorava desde a Aula 1. Entre versicolor e virginica o agrupamento se confunde um pouco, pelo mesmo motivo de sempre: essas duas espécies se sobrepõem no espaço de atributos. O ARI (Adjusted Rand Index) resume essa concordância entre grupos e espécies em um número entre -1 e 1 — usamos e interpretamos esse índice no exercício.

O que guardar desta sessão

- A pergunta que decide o paradigma: existe rótulo? Existe recompensa por ação? Nenhum dos dois?
- Supervisionado se divide em classificação (y categórico) e regressão (y numérico contínuo).
- Não supervisionado não é "pior": é a situação mais comum na prática, quando não há rótulo disponível.
- K-Means agrupa sem nunca ver y ; comparar clusters com y só é possível em datasets didáticos, como recurso de verificação.