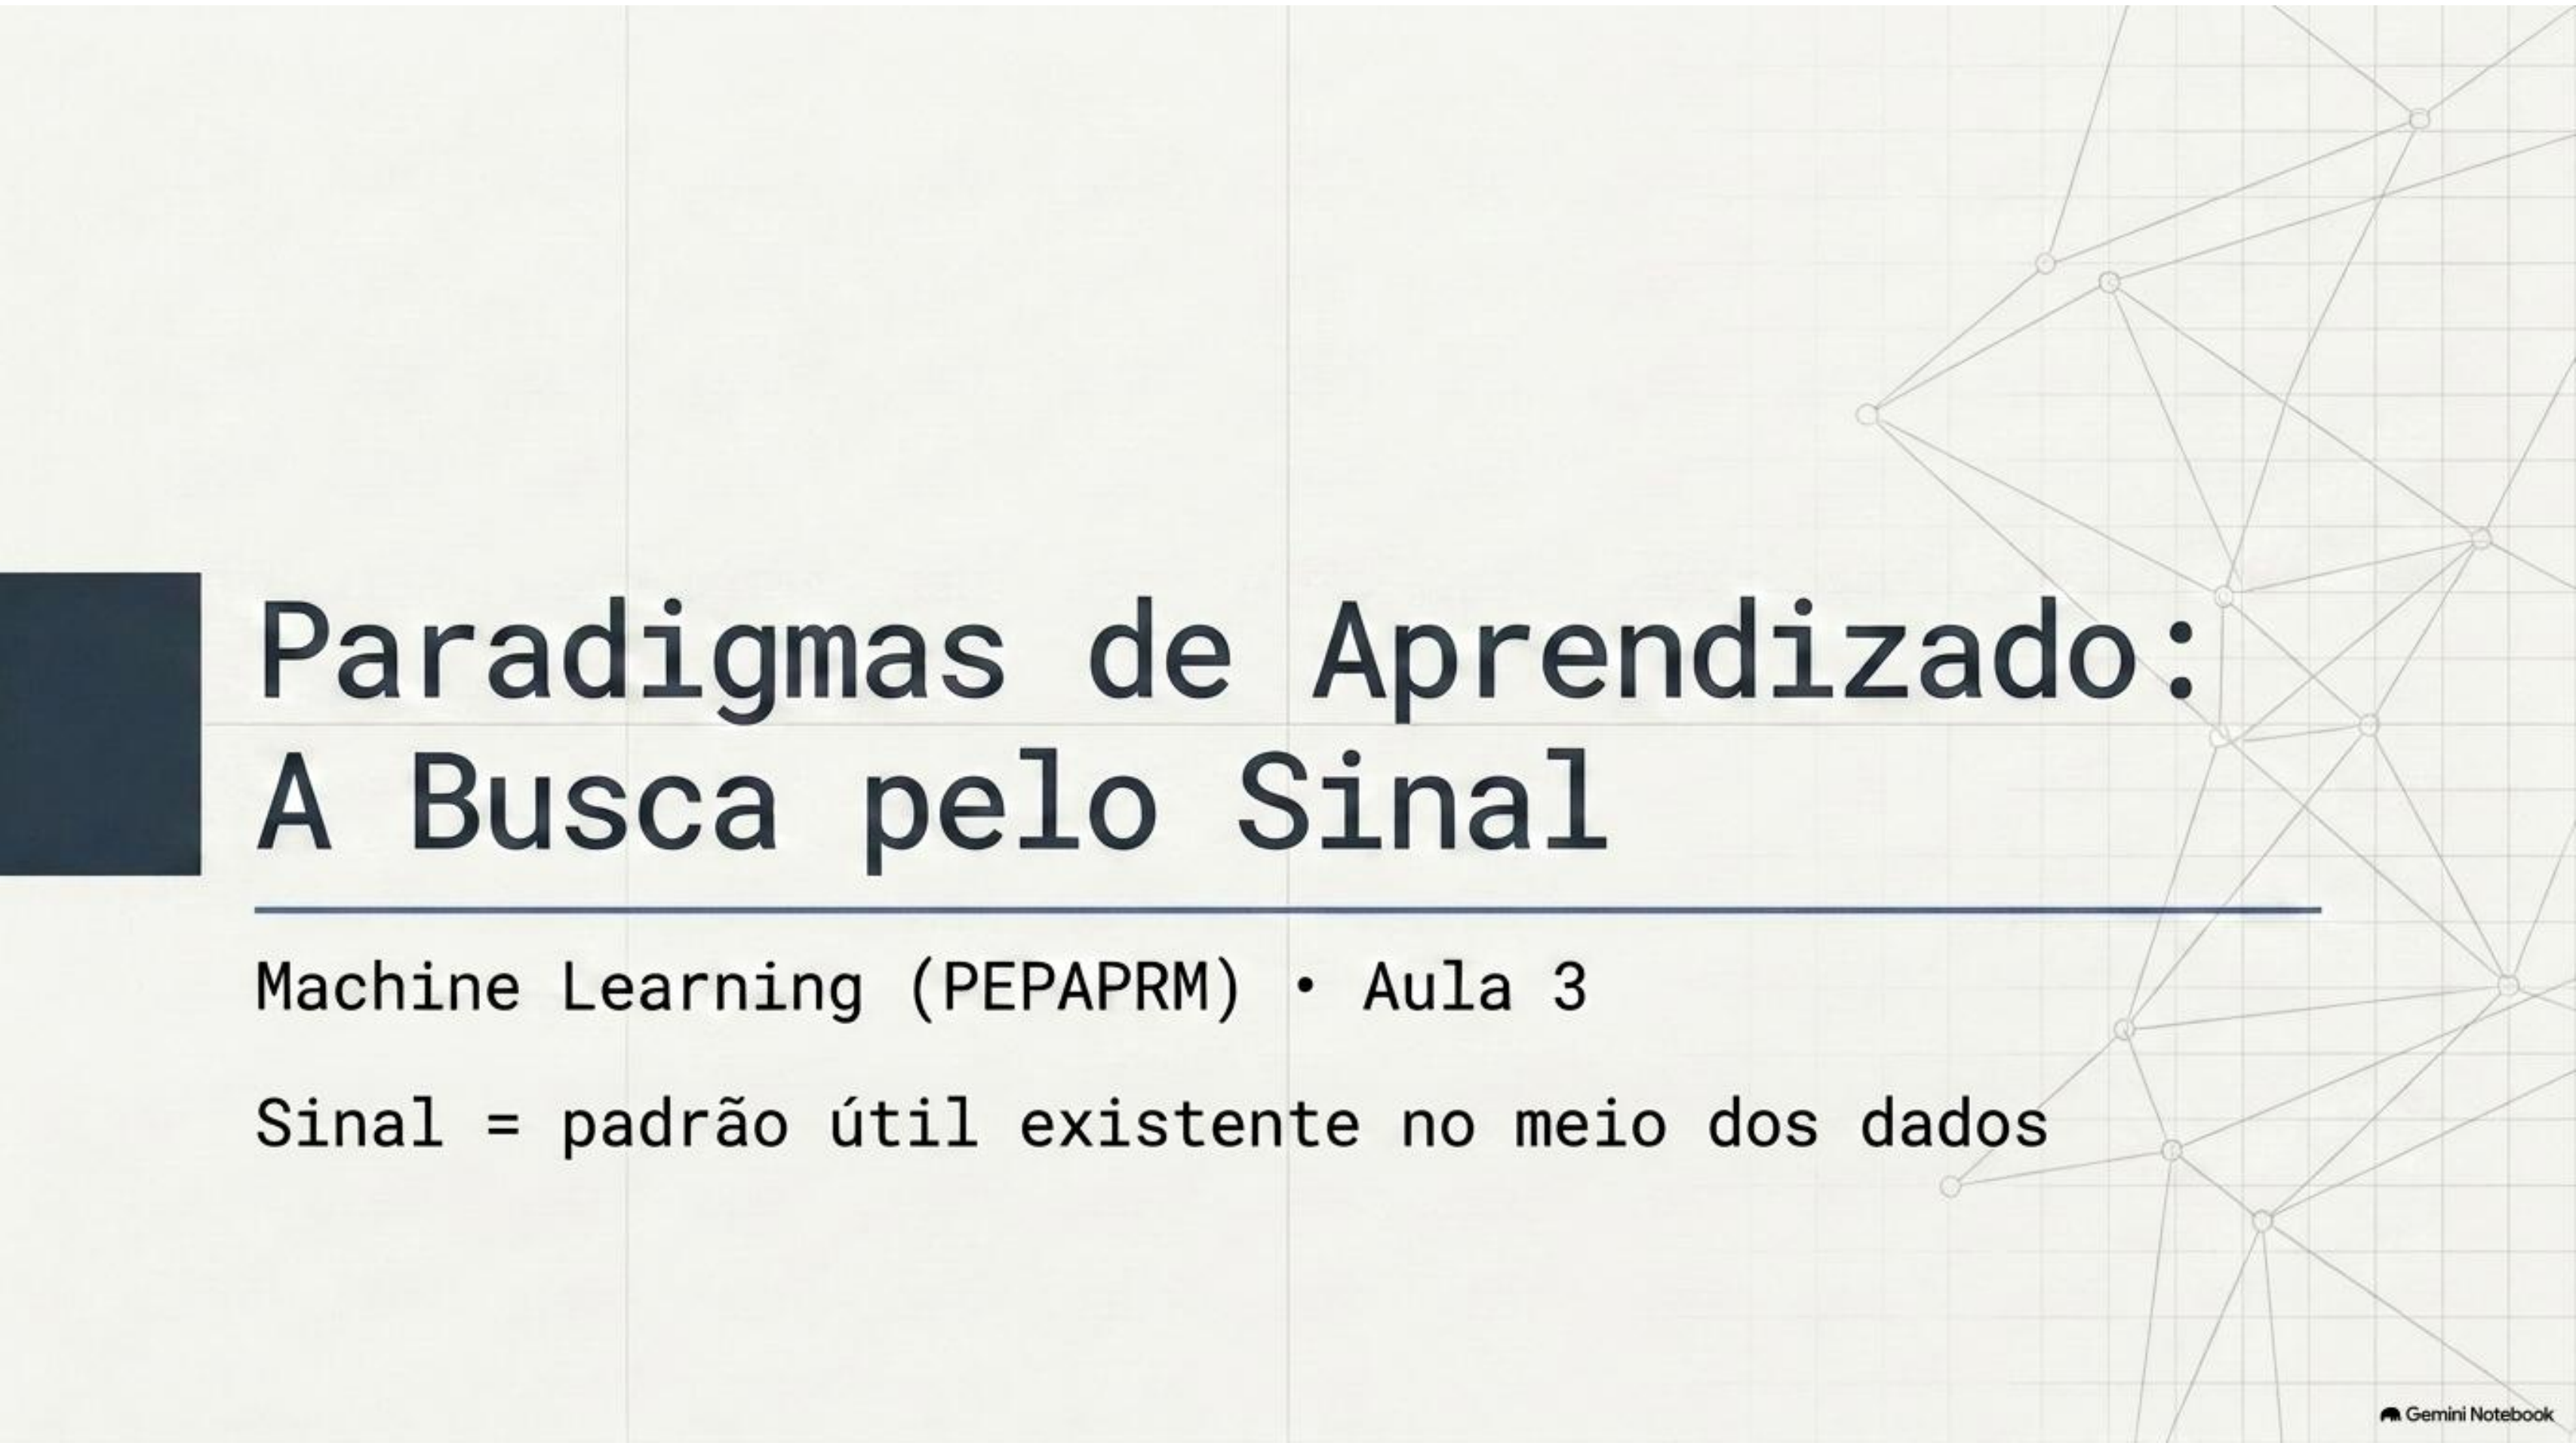




Paradigmas de Aprendizado: A Busca pelo Sinal

Machine Learning (PEPAPRM) • Aula 3

Sinal = padrão útil existente no meio dos dados


0 Ponto de Partida: Quando o rótulo desaparece

Nas duas primeiras semanas, treinamos e avaliamos o K-NN (Iris e Wine). Todo conjunto de atributos (X) tinha uma resposta exata (y).

{ Mas e quando a coluna y é um Null gigantesco? }

X_1	X_2	X_3	y (Rótulo)
0.452	1.234	-0.876	[Null]
3.141	0.005	2.718	[Null]
0.618	1.414	0.577	[Null]
-0.293	4.201	0.999	[Null]
1.732	0.101	5.050	[Null]


O algoritmo de decisão do Engenheiro de ML



0 Cheat Sheet dos Paradigmas

Paradigma	Sinal Disponível	Objetivo Algorítmico	Exemplo Prático
Supervisionado	Rótulo y conhecido	Prever y em dados novos	Espécie de uma flor
Não Supervisionado	Nenhum rótulo	Descobrir estrutura oculta	Agrupar clientes
Semi-supervisionado	Rótulos raros/esparsos	Usar y raro para ancorar o resto	Classificar e-mails
Por Reforço	Recompensa numérica contínua	Aprender política de ações	IA jogando xadrez

Supervisionado: 0 Mapeamento Exato



`type(y) == Categoria`

Classificação

- Variável discreta (espécie, cultivar, spam).
- Visto na Aula 1 com K-NN.


`type(y) == Número Contínuo`

Regressão

- Variável contínua (preço, temperatura).

A Regra do Embaralhamento: A ordem importa?

Classificação




Se embaralharmos as categorias, a ordem lógica se quebra? Não. Setosa não é matematicamente "menor" que Virginica.

Regressão



R\$ 200k é matematicamente menor que R\$ 300k. A relação de grandeza e ordem é o que o modelo aprende.

Não Supervisionado: Descrivendo Estruturas



1. Agrupamento (Clustering)

Separar exemplos em grupos por similaridade (Aulas 9 e 10).

2. Redução de Dimensionalidade


Resumir muitos atributos em poucos, preservando o essencial (Aulas 4 e 11).

3. Detecção de Anomalias

Encontrar exemplos que destoam do padrão geral (outliers).

O Mito do Não Supervisionado


O Mito: “Não ter supervisão significa que o algoritmo é falho, sem correção ou menos inteligente.”



A Realidade

- É o estado nativo do Big Data. A vasta maioria dos dados do mundo não nasce com a coluna y preenchida.
- Rotular custa tempo, dinheiro e exige intervenção de especialistas humanos.
- A ausência do rótulo não é uma limitação acadêmica, é uma necessidade de engenharia de software.

Semi-Supervisionado: A Fronteira Intermediária




O hack da indústria: Rotular é caro. Usamos uma fração minúscula de rótulos de alta precisão (âncoras) para contaminar e inferir padrões em um vasto oceano de dados não estruturados, generalizando muito melhor do que usariamos apenas com os dados isolados.

Por Reforço: O Fim do Dataset Estático



Aqui não há gabarito. Um agente interage, modifica a física do ambiente e recebe feedback instantâneo.

O Dicionário de Reforço (Exemplo: AlphaGo)



Agente:	O script ou algoritmo tomando as decisões (o jogador).
Ambiente:	A engine do tabuleiro e as regras do jogo.
Estado:	A matriz posicional exata das peças neste milissegundo.
Ação:	O vetor de movimento de uma peça.
Recompensa:	Sinal numérico (+1 vitória, -1 derrota).
Política:	A função matemática final mapeando Estado para Ação.

A Prática: K-Means 'Cego' no Dataset Iris

```
from sklearn.datasets import load_iris
from sklearn.cluster import KMeans
```

```
dados = load_iris()
X = dados.data
```

```
kmeans = KMeans(n_clusters=3, random_state=42, n_init=10)
clusters = kmeans.fit_predict(X)
```

```
print(clusters[:10])
```

Note: O rótulo nativo (y) foi descartado. O fit_predict recebe apenas atributos numéricos crus. O agrupamento ocorre puramente pela geometria do espaço dimensional.

O Paradoxo da Verificação Didática

Laboratório Acadêmico

```
y = dados.target  
print(pd.crosstab(y, clusters))  
print('ARI:',  
      adjusted_rand_score(y, clusters))
```


Neste cenário didático, usamos a matriz de confusão (crosstab) e a métrica ARI apenas porque conhecemos o 'y' secreto das flores. O objetivo é estudar a sobreposição do algoritmo.

Produção Real (Big Data)

```
y = [ NÃO EXISTE ]  
print(pd.crosstab( ???, clusters))
```

No mundo real, usar Aprendizado Não Supervisionado significa assumir que o gabarito é inexistente. A comparação cruzada com a realidade não ocorre, pois a estrutura descoberta É o resultado final.

Lendo a Geometria Espacial (A Métrica ARI)



Sobreposição Natural:
Força o centroide do
K-Means a traçar
fronteiras ambíguas.

Isolamento Perfeito:
Atributos naturais
não se misturam no
espaço matemático.

O Termômetro ARI (Adjusted Rand Index)

Resume a concordância
entre o agrupamento
geométrico cego e o
gabarito biológico real
em uma escala de $[-1, 1]$.


Quanto mais nítida for a
geometria do dado, mais
próximo de 1.

O Blueprint do Machine Learning

Supervisionado

$$f(X) = y$$

A Previsão Lógica.
Dominado pela presença de um gabarito estruturado. Subdivide-se em Classificação (y categórico) e Regressão (y contínuo).



Não Supervisionado

$$f(X) = \text{Estrutura}$$

O Mapeamento Espacial.
Navegação às cegas por puro volume de dados crus. A busca pela entropia e por clusters espaciais na era do Big Data.



Por Reforço

Estado $\rightarrow$ Ação

A Máquina de Interação.
Aprendizado contínuo onde a resposta certa não é dada por um rótulo, mas descoberta pela recompensa ambiental.



A regra de ouro arquitetônica: O tipo de sinal dita a engenharia.