


Paradigmas de Aprendizado: Supervisionado vs. Não Supervisionado

Laboratório 3 — Comparação arquitetural,
armadilhas de escala e métricas de avaliação.



O Experimento de Hoje

1 Dataset. 2 Algoritmos. 2 Paradigmas fundamentalmente diferentes.



1

Comparação Direta: K-NN e K-Means no mesmo espaço de dados.

2

Matemática da Escala: Por que algoritmos de distância falham sem padronização.

3

Desconstrução do Rótulo: O uso de 'y' como mero recurso pedagógico.


4

Métricas de Avaliação: A diferença crítica entre **Acurácia** e **ARI**.

O Ponto de Partida: O Dataset Wine


- ▀ 178 amostras de vinho.
- ▀ 13 atributos químicos.
- ▀ 3 cultivares reais (nosso alvo 'y' oculto).

Magnésio



Valores na casa das
dezenas ($\sim 10^1$)


Prolina



Valores na casa dos
milhares ($\sim 10^3$)

Matrizes heterogêneas carregam um viés matemático nativo. Sem tratamento, a diferença de grandeza destruirá qualquer cálculo de distância.

A Bifurcação: Para onde vai o 'y'?



// ALERTA ARQUITETURAL: O K-Means nunca enxerga o vetor 'y' durante a criação de suas fronteiras de decisão.

Caminho Supervisionado (K-NN): O Padrão Ouro

```
knn = make_pipeline(StandardScaler(),  
                    KNeighborsClassifier(n_neighbors=5))  
  
knn.fit(X_treino, y_treino)  
  
accuracy_score(y_teste, knn.predict(X_teste))
```

Embutido no pipeline por padrão de projeto.

y_treino atua como o "gabarito" no treinamento.

y_teste atua como juiz final na avaliação.

Caminho Não Supervisionado (K-Means): Padrões Ocultos

```
kmeans = KMeans(n_clusters=3)  
clusters = kmeans.fit_predict(X)
```

Sem o 'y', este hiperparâmetro força o algoritmo a criar fronteiras matemáticas próprias.

Todo o 'X' é processado de uma vez só (não há split treino/teste).

y

O "y" não entra no modelo. Ele só será resgatado na última linha do script para fins puramente de validação acadêmica.

O Inimigo Comum: A Maldição da Escala

A Maldição da Escala

Executar o K-Means (ou K-NN) **sem padronizar** os dados gera **métricas de acerto baixíssimas**. Por quê?

Sendo baseados em distância euclidiana, ambos os algoritmos são "míopes". O cálculo matemático acha que a Prolina (em milhares) é a única feature que importa, ignorando as demais sutilezas químicas do vinho.


$$\sqrt{(Prolina_1 - Prolina_2)^2 + (magnésio_1 - magnésio_2)^2 \dots + (outras\ features)^2}$$

O problema não é o algoritmo K-Means. É a geometria dos dados brutos.


A Cura Universal: StandardScaler

```
X_padronizado = scaler.fit_transform(X)
```

Geometria Distorcida (Dados Brutos)



Geometria Equilibrada (Dados Padronizados)




A Regra de Ouro

A mesma causa (distância dominada por uma única coluna) **exige o mesmo remédio** (StandardScaler). Seja no aprendizado supervisionado ou não supervisionado, algoritmos baseados em distância exigem padronização. O desempenho (ARI) do K-Means salta drasticamente após a transformação.

A Armadilha da Acurácia no K-Means

NUNCA utilize `accuracy_score(y, clusters)`.

Dizer “O K-Means acertou X% dos cultivares” é matematicamente falso.



O K-Means não prevê rótulos literais. Ele agrupa similaridades matemáticas.

O nome que o algoritmo dá ao grupo (0, 1 ou 2) é 100% arbitrário.


O Cenário Fatal: Se todos os vinhos da Classe Verdadeira '0' caírem perfeitamente no Cluster '2', o agrupamento foi perfeito. Porém, a métrica de acurácia marcará 0% de acerto para essas amostras porque os números literais não batem.

O Paradigma Correto: Adjusted Rand Index (ARI)

O ARI ignora os números arbitrários dos rótulos. Ele avalia exclusivamente a concordância estrutural.

A pergunta que o ARI faz:
"Se dois pontos pertencem à mesma classe verdadeira no mundo real, eles caíram dentro do mesmo cluster no modelo?"

Estrutura vs Rótulo Literal



```
adjusted_rand_score(y,  
clusters_com_pad)
```

Uso: É a única métrica segura para comparar agrupamentos matemáticos com um 'y' conhecido em ambientes de laboratório didático.

Matriz de Síntese: K-NN vs. K-Means

	K-NN (Supervisionado)	K-Means (Não Supervisionado)
Uso do 'y' no Treino	Sim (Mapeamento de padrões)	Não (Variável desconhecida)
Avaliação Principal	Acurácia (Previsões literais)	ARI (Concordância estrutural)
Sensível à Escala	Sim (Distância Euclidiana)	Sim (Distância Euclidiana)
Pré-requisito Crítico	StandardScaler()	StandardScaler()