


A Refinaria de Dados

Transformando a matéria-prima do mundo real em matrizes otimizadas para Machine Learning.



Princípios de Caracterização,
Pipelines e Scikit-Learn.

0 algoritmo não conserta os problemas que já estão na entrada.

The Academic World				
✓ Pronto para o Algoritmo				
Feature 1	Feature 2	Feature 3	Feature 4	Target
1.0	5.2	9.8	2.1	0
2.4	3.7	8.1	1.5	1
3.9	6.6	7.3	4.0	0
1.5	4.1	6.9	2.7	1
2.8	3.3	5.5	1.2	0
4.2	5.8	8.4	3.9	1

Dados Estruturados

The Real World				
⚠ 0 Algoritmo Falha Aqui				
Feature 1	Feature 2	Feature 3	Feature 4	Target
1.0	"Erro"	NaN	2.1	0
NaN	3.7	8.1	1.5	"Sim"
3.9	6.6	7.3	NaN	0
"N/A"	4.1	6.9	2.7	1
2.8	3.3	5.5	1.2	Ausente
4.2	Idade: 300	8.4	3.9	1

Dados Não Estruturados / Sujos


Pular a etapa de preparação é a causa mais comum de um modelo que "não funciona". O defeito raramente está na matemática; quase sempre está na matéria-prima.

0 Checklist da Inspeção Inicial (EDA)

Antes de qualquer modelagem, responda a três perguntas fundamentais sobre o seu dataset:
Qual o tamanho? Qual o tipo de cada coluna? Onde estão as falhas?

Diagnostic Terminal

`df.shape`




Dimensões do
Conjunto de Dados

`df.dtypes`



Tipos de Dados por Coluna
(Numérico, Categórico)


`df.isna().sum()`



Dados Faltantes
(Valores Nulos)


Os quatro problemas fundamentais dos dados crus.

Valores Ausentes NaN



Quebram a execução do código.

Outliers




Distorcem as métricas e médias.

Variáveis Categóricas




Incompreensíveis para cálculos de distância.

Escalas Diferentes



Atributos de alta amplitude esmagam os menores.


O dilema dos valores ausentes: Descartar ou Imputar.



Em pandas, representados como **NaN**. Se poucas linhas são afetadas, descartar é o caminho mais seguro. Para não perder volume, a imputa preenche as lacunas (geralmente com **média**, **mediana** ou **moda**), mas introduz um viés sintético.

Caçando Outliers:

A bússola do Intervalo Interquartil (IQR).



A regra do $1.5 \times IQR$ aponta exatamente onde você deve olhar.
Mas atenção: ela apenas **sinaliza a anomalia**. A decisão de remover, corrigir ou manter é exclusiva do engenheiro de dados.


O perigo fatal da falsa hierarquia categórica.



Para a álgebra do K-NN, 'MG' é o dobro de 'RJ'?
'MG' está mais longe de 'SP' do que 'RJ'? FALSO!

Algoritmos não leem texto. O erro mais comum é aplicar códigos numéricos arbitrários (0, 1, 2) em variáveis nominais. Isso cria uma relação de distância escalar e ordem que não existe na realidade, corrompendo completamente o modelo matemático.


A solução: Quebrando categorias com One-Hot Encoding.




A codificação One-Hot transforma uma única coluna de texto em múltiplas colunas binárias ortogonais. Isso garante que todas as categorias tenham exatamente a mesma 'distância' entre si, sem introduzir nenhuma ordem artificial.

A Guerra das Escalas e o domínio da amplitude.

Quando atributos estão em escalas diferentes, a distância Euclidiana é sequestrada pela coluna de maior valor numérico. Padronização ou Normalização são remédios obrigatórios para K-NN, K-Means e modelos lineares.




StandardScaler
(média 0, desvio 1)




Min-Max
(intervalo fixo [0,1])

$$d(p, q) = \sqrt{(p_1 - q_1)^2 + (\mathbf{p_{Renda} - q_{Renda}})^2 + \dots + (p_n - q_n)^2}$$



A engenharia em ação: Automatizando com **ColumnTransformer**.




Em vez de transformar coluna por coluna manualmente, o Scikit-Learn permite rotear grupos de dados por "esteiras" específicas, aplicando sequências exatas de limpeza e codificação em um único objeto.

O Paradoxo da Viagem no Tempo (Data Leakage).



Vazamento de dados ocorre quando informações do conjunto de teste influenciam o treinamento do modelo. Isso infla artificialmente as métricas de avaliação e cria uma ilusão perigosa sobre a capacidade real de generalização do algoritmo.


A Regra de Ouro da Transformação



Qualquer transformação que 'aprende' algo dos dados deve ser ajustada exclusivamente no conjunto de treino. O conjunto de teste é tratado como dados novos que acabaram de chegar do mundo real.

O atalho didático que destrói modelos em produção.

```
X_pronto = prep.fit_transform(X)
```



*Requer train_test_split
antes de aplicar!*

Executar o `fit_transform` no dataset inteiro de uma só vez força o transformador a enxergar dados que deveriam estar ocultos no teste. Nunca faça isso em projetos reais.

O Blueprint da Preparação de Dados



EDA é lei

Nunca modele sem rodar `shape`,
`dtypes` e `isna().sum()`



Trade-off de NaNs

Descartar custa dados reais;
imputar cria estimativas artificiais.



IQR aponta, não deleta

A matemática sinaliza a anomalia,
o engenheiro decide a ação.



One-Hot para texto

Evite falsas hierarquias.
Algoritmos matemáticos não
interpretam categorias.



Previna o Leakage

Ajuste (`fit`) apenas no treino.
Aplique (`transform`) no treino e
no teste.