

Aula 5 — Parte 2

Laboratório: Cálculo de Distâncias e Construção de Matriz de Similaridade em Python

Objetivos desta sessão

1. Construir uma matriz de distância Euclidiana, bruta e padronizada, para um grupo de solicitantes.
2. Comparar Manhattan e cosseno sobre os mesmos dados padronizados, e reconhecer quando eles concordam ou discordam.
3. Aplicar a distância de Jaccard sobre um atributo nominal codificado em one-hot.
4. Converter uma matriz de distância (dissimilaridade) em uma matriz de similaridade.
5. Visualizar uma matriz de similaridade como um mapa de calor, e reconhecer por que isso ajuda mais do que uma tabela de números para datasets maiores.

1. Retomada: de 4 para 8 solicitantes

Na Parte 1 (31/08) trabalhamos os conceitos com um grupo pequeno de 4 solicitantes, olhando só idade e renda. Hoje escalamos para 8 solicitantes e para as 4 colunas numéricas do dataset (idade, renda, tempo_emprego, score_credito), mais a coluna categórica cidade — o mesmo dataset de solicitações de empréstimo das Aulas 4.1, 4.2 e 5.1:

	idade	renda	tempo_emprego	score_credito	cidade
S1	47.0	5230.91	9.0	583.0	Outra
S2	52.0	5104.61	4.0	484.0	RJ
S3	44.0	2919.42	12.0	561.0	Outra
S4	28.0	4103.63	13.0	613.0	SP
S5	42.0	2085.69	14.0	627.0	RJ
S6	26.0	6297.35	10.0	805.0	Outra
S7	37.0	5333.78	0.0	573.0	Outra
S8	36.0	1751.73	5.0	678.0	MG

2. Matriz de distância Euclidiana: bruta x padronizada

O mesmo código do Bloco 3 da Parte 1 (pairwise_distances, do scikit-learn) escala direto de 4 para 8 solicitantes — e para as 4 colunas numéricas de uma vez, sem precisar mudar nada na chamada:

```
SEM padronizar:
```

	S1	S2	S3	S4	S5	S6	S7	S8
S1	0.0	160.6	2311.6	1127.8	3145.5	1089.5	104.2	3480.5
S2	160.6	0.0	2186.6	1009.6	3022.3	1235.5	246.3	3358.5
S3	2311.6	2186.6	0.0	1185.5	836.3	3386.8	2414.4	1173.6
S4	1127.8	1009.6	1185.5	0.0	2018.0	2202.1	1230.9	2352.8
S5	3145.5	3022.3	836.3	2018.0	0.0	4215.5	3248.6	338.0
S6	1089.5	1235.5	3386.8	2202.1	4215.5	0.0	991.2	4547.4
S7	104.2	246.3	2414.4	1230.9	3248.6	991.2	0.0	3583.6
S8	3480.5	3358.5	1173.6	2352.8	338.0	4547.4	3583.6	0.0

```
COM padronizacao (StandardScaler nas 4 colunas numericas):
```

	S1	S2	S3	S4	S5	S6	S7	S8
S1	0.00	1.67	1.67	2.54	2.41	3.60	2.29	2.92
S2	1.67	0.00	2.57	3.80	3.52	4.98	2.22	3.61
S3	1.67	2.57	0.00	2.13	1.04	4.12	3.14	2.34

S4	2.54	3.80	2.13	0.00	2.12	2.67	3.15	2.59
S5	2.41	3.52	1.04	2.12	0.00	3.95	3.78	2.17
S6	3.60	4.98	4.12	2.67	3.95	0.00	3.69	3.61
S7	2.29	2.22	3.14	3.15	3.78	3.69	0.00	2.80
S8	2.92	3.61	2.34	2.59	2.17	3.61	2.80	0.00

Um cuidado importante

Sem padronizar, o par mais parecido é S1-S7 (104,23) — depois de padronizar, passa a ser S3-S5 (1,04): o par mais próximo MUDOU, diferente do exemplo pequeno da Parte 1, onde o par mais próximo se manteve. Com mais atributos e mais exemplos, esse efeito fica mais forte: renda, em escala de milhares, domina a distância bruta e pode até trocar quem "parece" mais próximo de quem, não só reordenar os demais pares.

3. Manhattan e cosseno (sobre os dados padronizados)

Sobre os mesmos dados padronizados, comparamos mais duas métricas:

Manhattan (padronizada):

	S1	S2	S3	S4	S5	S6	S7	S8
S1	0.00	2.87	2.73	4.18	4.18	5.89	3.32	5.46
S2	2.87	0.00	4.95	6.89	6.89	8.76	3.79	6.44
S3	2.73	4.95	0.00	3.45	1.95	7.47	5.11	4.53
S4	4.18	6.89	3.45	0.00	3.32	4.45	5.12	4.92
S5	4.18	6.89	1.95	3.32	0.00	7.46	6.31	3.45
S6	5.89	8.76	7.47	4.45	7.46	0.00	6.70	6.60
S7	3.32	3.79	5.11	5.12	6.31	6.70	0.00	4.67
S8	5.46	6.44	4.53	4.92	3.45	6.60	4.67	0.00

Cosseno (padronizada) - o valor e a DISTANCIA, ou seja 1 - similaridade:

	S1	S2	S3	S4	S5	S6	S7	S8
S1	0.00	0.23	0.80	1.53	1.21	1.31	0.89	1.77
S2	0.23	0.00	0.82	1.73	1.37	1.68	0.48	1.41
S3	0.80	0.82	0.00	0.98	0.18	1.72	1.66	1.03
S4	1.53	1.73	0.98	0.00	0.75	0.53	1.45	1.10
S5	1.21	1.37	0.18	0.75	0.00	1.30	1.91	0.70
S6	1.31	1.68	1.72	0.53	1.30	0.00	1.03	1.06
S7	0.89	0.48	1.66	1.45	1.91	1.03	0.00	1.03
S8	1.77	1.41	1.03	1.10	0.70	1.06	1.03	0.00

Cosseno compara o ângulo entre os vetores, não o tamanho da diferença — dois solicitantes com o mesmo "perfil relativo" entre as colunas (mesmo se um tiver valores maiores em tudo) ficam com distância de cosseno baixa. É por isso que cosseno é mais usado quando a direção do vetor importa mais que sua magnitude (comum em vetores de texto); aqui a padronização já tira grande parte do efeito de magnitude, então Euclidiana e cosseno tendem a concordar sobre quem está mais perto de quem — mas não sempre, como o Exercício 2 de hoje vai mostrar.

4. Jaccard sobre a cidade (atributo nominal)

categorias (one-hot): ['MG', 'Outra', 'RJ', 'SP']

Jaccard (cidade):

	S1	S2	S3	S4	S5	S6	S7	S8
S1	0.0	1.0	0.0	1.0	1.0	0.0	0.0	1.0
S2	1.0	0.0	1.0	1.0	0.0	1.0	1.0	1.0
S3	0.0	1.0	0.0	1.0	1.0	0.0	0.0	1.0
S4	1.0	1.0	1.0	0.0	1.0	1.0	1.0	1.0
S5	1.0	0.0	1.0	1.0	0.0	1.0	1.0	1.0
S6	0.0	1.0	0.0	1.0	1.0	0.0	0.0	1.0
S7	0.0	1.0	0.0	1.0	1.0	0.0	0.0	1.0
S8	1.0	1.0	1.0	1.0	1.0	1.0	1.0	0.0

S1, S3, S6 e S7 são todos de "Outra" — todo par dentro desse grupo tem Jaccard = 0,00. Qualquer par com cidades diferentes tem Jaccard = 1,00, porque com uma única coluna categórica virada one-hot não existe "meio caminho": ou os dois solicitantes compartilham a categoria (0), ou não compartilham nada (1).

5. Construindo a matriz de similaridade completa

Uma matriz de similaridade é o espelho de uma matriz de dissimilaridade (distância): quanto maior a distância, menor a similaridade. Para distâncias normalizadas entre 0 e um valor máximo (como a Euclidiana padronizada), uma forma simples de converter é:

```
similaridade = 1 - (distancia / distancia_maxima)
```

Aplicando essa fórmula à matriz Euclidiana padronizada do Bloco 2 (distância máxima = 4,98):




Figura 1 — matriz de similaridade dos 8 solicitantes, a partir da Euclidiana padronizada. Quanto mais escuro, mais parecidos os dois solicitantes.

A diagonal principal é sempre 1,00 (todo solicitante é idêntico a si mesmo) e a matriz é simétrica — $\text{similaridade}(S_x, S_y) = \text{similaridade}(S_y, S_x)$. O par mais parecido do grupo é S3-S5, com similaridade 0,79 — o mesmo par que tinha a menor distância Euclidiana padronizada no Bloco 2 (1,04): são o mesmo resultado, vistos de dois ângulos diferentes.

Por que um mapa de calor, e não só a tabela

Com 8 solicitantes, a tabela de números ainda é legível. Mas a matriz cresce com o quadrado do número de exemplos: 100 solicitantes já dão 10.000 valores, e 500 dão 250.000 — nenhuma tabela é legível nessa escala. Um mapa de calor converte cada número numa cor, e o olho humano é muito bom em notar blocos de cor parecida (grupos de exemplos semelhantes) quase instantaneamente, o que seria impraticável numa tabela do mesmo tamanho.

O que guardar desta sessão

- O mesmo código de distância (pairwise_distances) escala de 4 para centenas de exemplos sem mudar — o que muda é só o tamanho da matriz resultante.
- Sem padronizar, uma única coluna de escala maior pode dominar a distância a ponto de TROCAR qual par de exemplos parece mais próximo, não apenas reordenar os demais.
- Cosseno e Euclidiana padronizada costumam concordar sobre o par mais próximo, mas podem discordar bastante mais adiante no ranking — cosseno compara direção, Euclidiana compara distância direta.

- Jaccard, sobre um atributo nominal codificado em one-hot, só assume 0 (mesma categoria) ou 1 (categorias diferentes) quando há uma única coluna categórica.
- Uma matriz de similaridade é o espelho de uma matriz de distância — e um mapa de calor é a forma prática de enxergar essa matriz quando ela cresce além de poucos exemplos.