


A Geometria dos Dados

Medindo Similaridade no
Aprendizado de Máquina




O Falho Silencioso

The Illusion

```
> K-NN Classifier... Executed.  
> Exit code: 0  
> Status: Success.
```




The Reality




Algoritmos como **K-NN** e **K-Means** não perguntam se a sua matemática faz sentido. Usar a métrica de distância errada sobre os dados não gera um **erro de código** — gera um resultado **silenciosamente sem sentido**. A precisão exige entender a natureza do atributo.



O Espectro do Poder Matemático



Mapeando o Terreno do Dataset



A Mecânica da Distância Numérica




A VULNERABILIDADE VITAL:
Ambas somam diretamente as diferenças de cada eixo.



A Armadilha da Escala


	Idade	Renda
S1:	47.0	5230.91
S7:	37.0	5333.78



Sem padronizar, a coluna de maior amplitude domina a equação.
O algoritmo determina cegamente que S1 e S7 são o par mais próximo do dataset (Distância Euclidiana: 104,2), ignorando totalmente a diferença de 10 anos de idade.


A Verdadeira Topologia (StandardScaler)

Novo par mais próximo: S3 e S5
Distância Euclidiana Padronizada: 1,04
S1 e S7 agora estão distantes: 2,29



Ao equalizar os eixos com StandardScaler, a ilusão desmorona.
A padronização não apenas reordena as distâncias; ela muda completamente qual par é considerado o mais próximo.

Direção vs. Magnitude (Cosseno)




A distância de cosseno compara o ângulo entre os vetores, ignorando o tamanho absoluto da diferença.

Dois solicitantes com o mesmo perfil relativo entre as colunas (ex: gastam nas mesmas proporções, mesmo que um ganhe o triplo do outro) terão uma distância de cosseno extremamente baixa.

Nota Estrutural: Cosseno avalia a **intenção/perfil**, enquanto **Euclidiana** mede o **espaço literal**.


O Espaço Nominal: Distância de Jaccard

Cenário A: S1 ("Outra") e S3 ("Outra")



Distância: 0.0 (Sobreposição Total)

Cenário B: S1 ("Outra") e S4 ("SP")



Distância: 1.0 (Isolamento Total)

O Mecanismo


Euclidiana e Manhattan não fazem sentido sobre a variável "**cidade**" ('SP' menos 'RJ' não é um número). Transformamos a variável em **one-hot encoding**. A distância de Jaccard conta as **categorias ativas em comum**. Com uma única coluna categórica, o resultado é binário: **ou compartilham o espaço**, ou são **totalmente alienígenas** entre si.

A Matriz de Decisão de Distâncias

DATA TYPE	METRIC	PRE-REQUISITE
RACIONAL / INTERVALAR	EUCLIDIANA OU MANHATTAN	SEMPRE APLICAR STANDARDSCALER.
ORDINAL	MANHATTAN	CODIFICAR RÓTULOS RESPEITANDO A HIERARQUIA RÍGIDA.
NOMINAL	JACCARD	TRANSFORMAR VIA ONE-HOT ENCODING.
PERFIS RELATIVOS	COSSENO	USAR QUANDO A DIREÇÃO DO VETOR (COMPORTAMENTO RELATIVO) IMPORTA MAIS QUE A MAGNITUDE.

Invertendo a Lente

Dissimilaridade (Distância)



- Mede o espaço físico literal entre pontos.
- 0 = Idêntico / Sobreposto.
- Máximo = Oposto / Totalmente Distante.



Similaridade



- 0 espelho exato. Mede a proximidade conceitual.
- Fórmula: $1 - (\text{distância} / \text{distância_máxima})$
- 1.0 = Idêntico.
- 0.0 = Completamente distinto.



Visualizando a Escala: O Mapa de Calor

Matriz de similaridade – 8 solicitantes (Euclidiana padronizada)




A Diagonal: Sempre 1.00.
Todo indivíduo é
idêntico a si mesmo.

0 Ponto Fixo: 0
quadrante verde escuro
isolado em S3 e S5
(0.79) – o par mais
parecido, visualizado
instantaneamente sem ler
a tabela.

Para N=8, tabelas sobrevivem. Para N=500, geramos 250.000 valores. Matrizes de similaridade mapeadas em cores traduzem topologias matemáticas densas em instintos visuais humanos imediatos.

O Próximo Ponto Cego: A Ilusão do Holdout Único



Assim como uma métrica de distância crua engana um algoritmo, um único corte nos dados (holdout 70/30) pode enganar o cientista de dados. No nosso dataset, um split único relatou acurácia otimista de 0,8370.

0 k-fold revelou a verdade:

Flutuação: 0,72 a 0,84
Média real: 0,7844

**A validação cruzada não troca os dados; ela muda a pergunta.
De “qual a acurácia?” para “qual a estabilidade da acurácia?”.**