


Redução de Dimensionalidade: O Guia Definitivo

Dominando PCA, Kernel PCA
e LDA em Aprendizado de
Máquina.


Um projeto estrutural para Cientistas de
Dados e Engenheiros de Machine Learning.




O Problema: A Maldição da Dimensionalidade



1D (Linha)



2D (Quadrado)



3D (Cubo)

Esparsidade

O volume do espaço cresce exponencialmente, isolando as amostras.

Overfitting

Muitos recursos (features) e poucas amostras memorizam o ruído.


Custo Computacional

Explosão no tempo de treinamento e inferência.

Limites Visuais

A mente humana não enxerga além de 3D.


O Mapa das Técnicas



PCA: O Motor da Variância

Quais direções capturam a maior variância dos dados, sem olhar para os rótulos?

Insight: O PCA não inventa dados; ele rotaciona o nosso ponto de vista para o ângulo mais informativo.



Prática: Implementando o PCA

```
1 from sklearn.preprocessing import StandardScaler
2 from sklearn.decomposition import PCA
3
4 # 1. Padronização Obrigatória
5 X_scaled = StandardScaler().fit_transform(X)
6
7 # 2. Mantendo 95% da variância original
8 pca = PCA(n_components=0.95)
9 X_pca = pca.fit_transform(X_scaled)
10
11 # 3. Analisando a importância de cada componente
12 print(pca.explained_variance_ratio_)
13 print(pca.components_) # Loadings
14
```

Regra de Ouro: Sem padronização, a escala domina o modelo.


Em vez de adivinhar k , deixe o algoritmo reter $\geq 95\%$ da variância explicada acumulada.

Loadings: Valores altos indicam forte contribuição da variável original no componente gerado.

O Paradoxo da Classificação

Alta Variância $\neq$ Alta Separação

Direção PCA: Aponta para a direção onde os dados são mais compridos. Mas ao projetar aqui, as classes azul e laranja colidem e se misturam!



Direção LDA: A direção ótima. Ignora o comprimento da nuvem e foca exclusivamente no espaço vazio entre as duas cores.

Takeaway: PCA ignora rótulos. Se o objetivo final é classificar, precisamos de um especialista supervisionado.


Os Limites Matemáticos do LDA

```
from sklearn.discriminant_analysis import  
LinearDiscriminantAnalysis  
  
# ATENÇÃO: y (rótulos) são OBRIGATÓRIOS!  
lda = LinearDiscriminantAnalysis(n_components=1)  
X_lda = lda.fit_transform(X_scaled, y)
```

A Regra do C - 1


- O número máximo de componentes projetados é **rigidamente travado em Classes Totais - 1**.
- *Exemplo:* Em um problema de classificação binária (Gato vs Cachorro), o LDA **extraí no máximo 1 componente. Ele colapsa todo o espaço multidimensional em uma única linha decisória!**
- Resolvido via problema de autovalores generalizado: $S_W^{-1} S_B \mathbf{w} = \lambda \mathbf{w}$

A Regra de Ouro: Prevenindo Data Leakage



O **Vazamento de Dados (Data Leakage)** ocorre se você ajustar PCA ou LDA no **conjunto completo** antes da separação. O modelo de teste enxergaria o futuro, invalidando totalmente suas métricas!

O Fluxograma de Decisão



Entender a limitação matemática de cada ferramenta é o que separa um programador júnior de um Cientista de Dados Sênior.