



Modelos Preditivos: O Guia de Regressão

Da simplicidade linear à flexibilidade geométrica das curvas complexas.




Aula 6 | Aprendizado de Máquina
(PEPAPRM) | 8º Semestre

Classificação



Alvo (y) = Categórico
Exemplo: "Aprovado" (0 ou 1).
Tarefa: Separar grupos por fronteiras de decisão.

Regressão - O Foco de Hoje



Alvo (y) = Numérico Contínuo
Exemplo: Valor, Temperatura, Tempo.
Tarefa: Prever a magnitude em uma escala contínua.

O paradigma muda, mas a fundação matemática (X para atributos, y para alvo) mantém-se intacta.

Atributos (X):

Área: 82.6 m²

Quartos: 3

Distância ao Centro: 3.50 km

Alvo (y): Valor do Aluguel


R\$ 2246.05



Porquê Regressão?

O zero absoluto existe (R\$ 0 é possível) e as proporções fazem sentido matemático (R\$ 4000 é exatamente o dobro de R\$ 2000). Esta racionalidade contínua é a assinatura geométrica de um problema de regressão, exigindo modelos que prevejam magnitudes.

$$y_{\text{previsto}} = b0 + b1 * x$$



Exemplo de Cálculo da Reta Prevista

A fórmula permite calcular o valor de "y" na reta para qualquer valor de "x".

Exemplo 1: Para $x = 20$, o ponto previsto é $y_{\text{previsto}} = b0 + b1 * 20$.

Exemplo 2: Para $x = 40$, o ponto previsto é $y_{\text{previsto}} = b0 + b1 * 40$.

Estes cálculos geram os pontos exatos sobre a linha azul.

O Motor: Método dos Mínimos Quadrados...

O Método dos Mínimos Quadrados atua como o motor, calculando os coeficientes ($b0$ e $b1$) que resultam na linha com a menor soma de erros quadráticos.

Desconstruindo o Modelo Simples: Aluguel ~ Área

A Dinâmica (b1)

+ 21,78

Cada m² de área adiciona R\$ 21,78 ao aluguel previsto.

A Base Teórica (b0)

326,66


Valor previsto para área zero. Serve para ancorar a reta matematicamente, mas não deve ser interpretado no mundo real.

O Sinal de Qualidade (R²)

0,8133


Apenas a variável área explica 81,3% da variação do preço. Os restantes 18,7% representam ruído ou outras variáveis ocultas (quartos, distância).

Uma Dimensão



$$y_{\text{previsto}} = b_0 + b_1 * x_1$$

Múltiplas Dimensões



$$y_{\text{previsto}} = b_0 + b_1 * x_1 + b_2 * x_2 + \dots + b_p * x_p$$

O Paradigma: Continua a ser uma combinação LINEAR. A otimização dos mínimos quadrados opera agora num espaço multidimensional para encontrar o melhor plano de ajuste.

Novo $R^2 = 0,9169$

O ajuste melhora substancialmente com a inclusão de múltiplas variáveis.

Área



Quartos ($b = +153.49$)



Um quarto extra adiciona R\$ 153,49 ao valor, assumindo que a área e a distância permanecem exatamente iguais.


Distância ($b = -23.02$)



Cada km de afastamento reduz R\$ 23,02, assumindo a mesma área e o mesmo número de quartos.

A Regra de Ouro da Interpretação: A leitura rigorosa dos coeficientes na regressão múltipla exige o isolamento matemático das variáveis: "tudo o resto mantido constante".

O Limite da Linha Reta




A Armadilha do R^2

$$R^2 = 0,8753$$


O número parece razoável, mas a forma geométrica está fundamentalmente errada. A natureza nem sempre obedece a linhas retas. A economia de escala exige uma curva.

A Ilusão Polinomial: O Truque da Transformação




O Segredo: A Regressão Polinomial não é um algoritmo novo. O modelo continua linear nos coeficientes, mas a transformação dos dados (com o termo negativo em x^2) dobra a reta matematicamente, permitindo que o R^2 salte para 0,9752.

Mesmos dados, três formulações de regressão




Mudando as Regras: Support Vector Regression (SVR)



A Vantagem: Ao utilizar o kernel='rbf', o SVR traça curvas complexas nativamente, sem a necessidade de transformar manualmente os atributos em x^2 , x^3 , etc.


Afinando o Tubo SVR (Hiperparâmetros)

Dial 1: Epsilon (ϵ) - A Espessura do Tubo



- Um tubo largo tolera muito ruído, mas pode apagar os detalhes finos da curvatura.
- Um tubo estreito tem pouca tolerância, forçando o modelo a reagir a cada variação.


Dial 2: C - A Severidade da Punição



- **C Alto:** Persegue implacavelmente cada ponto fora do tubo (aumenta o risco de overfitting).
- **C Baixo:** Mais tolerante e preguiçoso, aceita violações em troca de uma curva mais suave.

Resultado no Dataset: SVR atinge $R^2 = 0,9756$ (kernel=rbf, $C=100000$, epsilon=2000), igualando a performance polinomial sem definição manual de grau.

O Arco da Qualidade de Ajuste (Evolução do R^2)



Alerta de Auditoria: Todo o R^2 analisado hoje foi medido sobre os próprios dados de treino. A validação real da qualidade exige dados invisíveis (teste).

Matriz de Seleção de Modelos

[Geometria da Relação]		[Modelo Recomendado]	[Classe Técnica]
Linear + 1 Atributo		Linear Simples	LinearRegression
Linear + Vários Atributos		Linear Múltipla (Ideal para isolar efeitos)	LinearRegression
Curvatura visível, conhecida, poucos atributos		Regressão Polinomial	PolynomialFeatures + LinearRegression
Curvas complexas, forma desconhecida, ruído		SVR (Kernel RBF)	sklearn.svm.SVR (Exige afinação de ϵ e C)