

Aula 6

Modelos Preditivos: Regressão Conceitos e Formulação

Objetivos desta sessão

- Distinguir problemas de regressão (alvo numérico contínuo) de problemas de classificação (alvo categórico), retomando os paradigmas já vistos.
- Formular regressão linear simples e múltipla: a combinação linear dos atributos, o método dos mínimos quadrados e como interpretar coeficientes.
- Entender regressão polinomial como a mesma regressão linear aplicada a atributos transformados ($x, x^2, \dots$), não como um algoritmo novo.
- Formular SVR (Support Vector Regression): a ideia de um tubo de tolerância de largura 2ϵ ao redor da função prevista.
- Reconhecer, em R^2 , uma primeira noção de qualidade de ajuste a formalização com resíduos, MAE e RMSE fica para o laboratório da Semana 7 (14/09).

1. De Classificação para Regressão

Anteriormente vimos que o aprendizado supervisionado se divide, pelo tipo do alvo (y), em duas famílias. Em CLASSIFICAÇÃO, y é uma categoria foi o caso de "aprovado" (0 ou 1) no dataset de solicitações de empréstimo das Aulas 4 e 5. Em REGRESSÃO, y é um número contínuo um preço, uma temperatura, um tempo. Até hoje só praticamos o primeiro lado.

O dataset de hoje muda o alvo para um valor contínuo: dado um anúncio de aluguel (área, número de quartos, distância até o centro), prever o valor do aluguel em reais.

	area_m2	quartos	distancia_km	valor_aluguel
0	82.6	3	3.50	2246.05
1	49.0	3	13.05	1128.66
2	93.8	3	1.29	2537.33
3	98.5	4	23.32	2113.33
4	28.0	1	13.07	927.63

Formulação do problema (mesmo vocabulário da Aula 2): X (atributos) = area_m2, quartos, distancia_km; y (alvo) = valor_aluguel. Pelo vocabulário da Aula 5.1, valor_aluguel é RACIONAL existe zero absoluto (R\$ 0 de aluguel é um valor possível) e razões fazem sentido (R\$ 4000 é o dobro de R\$ 2000). É essa característica do alvo um número contínuo e racional, não uma categoria que define a tarefa como regressão.

2. Regressão Linear Simples

A forma mais simples liga UM atributo ao alvo por uma reta:

$$y_{\text{previsto}} = b_0 + b_1 * x$$

b_0 (intercepto) e b_1 (coeficiente angular) são escolhidos minimizando a soma dos erros ao quadrado entre y_{previsto} e y real o método dos mínimos quadrados. É por isso que "ajustar" o modelo também se chama "treinar": treinar uma regressão linear é resolver esse problema de otimização, não iterar tentativa e erro.

Ajustando sobre $\text{valor_aluguel} \sim \text{area_m2}$, no dataset de hoje:

```
b0 (intercepto) = 326.66
b1 (coeficiente de area_m2) = 21.78
R^2 (proporcao da variacao de y explicada pelo modelo) = 0.8133
```

Cada m^2 a mais no imóvel está associado a +R\$ 21,78 no aluguel previsto, mantendo tudo o resto de fora do modelo (aqui só temos area_m2). O intercepto (R\$ 326,66) é o valor previsto para $\text{area_m2} = 0$ um número fora da faixa real dos dados, que só posiciona a reta mas não deve ser interpretado ao pé da letra. $R^2 = 0,8133$ significa que só a área explica 81,3% da variação do aluguel o resto vem de quartos, distância e ruído, que o modelo simples ignora. O ajuste fino de resíduos e métricas (MAE, RMSE) fica para o laboratório da Semana 7 (14/09); hoje o foco é a formulação.

3. Regressão Múltipla

Regressão múltipla estende a mesma ideia para vários atributos:

$$y_{\text{previsto}} = b_0 + b_1 * x_1 + b_2 * x_2 + \dots + b_p * x_p$$

Continua sendo uma combinação LINEAR dos atributos o que muda é que agora há mais de um coeficiente para interpretar. Ajustando $\text{valor_aluguel} \sim \text{area_m2} + \text{quartos} + \text{distancia_km}$:

```
b0 (intercepto) = 392.80
b (coeficiente de area_m2) = 17.33
b (coeficiente de quartos) = 153.49
b (coeficiente de distancia_km) = -23.02
R^2 = 0.9169
```

R^2 subiu de 0,8133 (só área) para 0,9169 (área + quartos + distância) as três variáveis juntas explicam mais da variação real do aluguel. Cada coeficiente agora se lê como "tudo mais mantido constante": um quarto a mais soma R\$ 153,49 ao aluguel previsto, para a MESMA área e distância; cada km a mais de distância do centro subtrai R\$ 23,02, para a mesma área e número de quartos.

4. Regressão Polinomial

Um novo cenário: preço de lotes de terreno por área. A regra usada para gerar esses dados tem um termo negativo em área^2 o preço por m^2 cai à medida que o lote cresce (economia de escala). Uma reta única não consegue descrever essa curvatura:

```
Regressao linear simples (so area_m2):      R^2 = 0.8753
Regressao polinomial (area_m2 e area_m2^2): R^2 = 0.9752
```

```
Coeficientes da polinomial: b1 (area_m2) = 487.06,
b2 (area_m2^2) = -0.5543, intercepto = 23421.58
```

Regressão POLINOMIAL não é um algoritmo novo é a mesma regressão linear (LinearRegression), só que aplicada a atributos TRANSFORMADOS (x e x^2 , criados pelo PolynomialFeatures) em vez do x original. O coeficiente de área^2

(negativo) é o que "curva" a reta, virando parábola. R^2 sobe de 0,8753 para 0,9752 porque agora o modelo pode acompanhar a curvatura real dos dados, em vez de tentar encaixar uma reta única onde ela não serve.




Figura 1 mesmos dados de lotes de terreno, ajustados por regressão linear, regressão polinomial de grau 2 e SVR: a reta subestima os lotes pequenos e superestima os grandes, enquanto a polinomial e o SVR acompanham a curva quase da mesma forma.

5. Support Vector Regression (SVR)

SVR adapta a ideia de margem do SVM (visto como família de algoritmos de classificação, para regressão: em vez de traçar uma fronteira entre classes, o SVR tenta encaixar um "tubo" de largura 2ϵ ao redor da função prevista. Pontos DENTRO do tubo não geram penalidade nenhuma (o modelo os considera "bons o suficiente"); só pontos FORA do tubo contam erro, e são eles que definem o formato final da curva (os vetores de suporte). Com `kernel="rbf"`, o SVR pode acompanhar curvas como a da Figura 1 sem exigir que a gente crie manualmente `area_m2²`.

```
SVR (kernel=rbf, C=100000, epsilon=2000): R^2 = 0.9756
```

O SVR chega a um R^2 (0,9756) na mesma faixa da polinomial (0,9752) mas sem que a gente precisasse decidir "grau 2" na mão. O preço desse ganho é ter dois novos hiperparâmetros para ajustar: `epsilon` (largura do tubo um tubo largo tolera mais ruído, mas pode "esconder" curvatura fina) e `C` (o quanto o modelo penaliza pontos fora do tubo `C` alto persegue cada ponto de perto, `C` baixo aceita um tubo mais "preguiçoso").

6. Qual Modelo Usar? Resumo Comparativo

Não existe um modelo de regressão "universal" a escolha depende de quantos atributos entram, se a relação é aproximadamente linear e se a forma da curva (quando existe) é conhecida:

Modelo	Formulação	Quando faz sentido usar
Linear simples	$y = b_0 + b_1x$	Um único atributo, relação aproximadamente em linha reta
Linear múltipla	$y = b_0 + b_1x_1 + \dots + b_px_p$	Vários atributos, cada um com efeito aproximadamente linear
Polinomial	$y = b_0 + b_1x + b_2x^2 + \dots$	Curvatura visível e conhecida, poucos atributos
SVR (kernel rbf)	tubo de largura 2ϵ em torno da função	Curvas complexas sem forma conhecida, ou robustez a ruído moderado

Na prática, a família Linear (simples, múltipla e polinomial) do scikit-learn compartilha a mesma classe LinearRegression a diferença está nos atributos que entram no X, não no algoritmo de ajuste. SVR já é uma classe própria (sklearn.svm.SVR), com seus próprios hiperparâmetros.

7. Prévia: o que vem na Semana 7 (14/09)

O laboratório da Semana 7 pega a regressão LINEAR de hoje e foca no que ainda falta: dividir treino e teste, examinar os RESÍDUOS (y real – y previsto) e calcular MAE, RMSE e R^2 formalmente, sobre dados de teste hoje R^2 apareceu só como prévia, para comparar as quatro formulações sobre os próprios dados de treino.

O que guardar desta sessão

- O tipo do alvo (y) decide o paradigma: categoria → classificação; número contínuo → regressão. O resto da formulação (X, treino, avaliação) segue igual.
- Regressão linear simples e múltipla resolvem o mesmo problema (mínimos quadrados) múltipla só tem mais de um coeficiente para interpretar, cada um "tudo mais constante".
- Regressão polinomial não é um algoritmo novo: é regressão linear sobre atributos transformados (x , x^2 , x^3 , ...) por isso corre o mesmo risco de qualquer regressão múltipla com muitos termos: overfitting quando o grau é alto demais para os dados.
- SVR troca a escolha manual do grau polinomial por dois hiperparâmetros (epsilon, C) e um kernel captura curvas sem exigir que a gente conheça a forma exata da relação.
- R^2 apareceu hoje só como prévia de comparação resíduos, MAE e RMSE (a avaliação formal, sobre dados de teste) são o assunto do laboratório da Semana 7 (14/09).