

Aula 7 Parte 1

Laboratório: Regressão Linear Ajuste, Resíduos e Métricas de Erro (MAE, RMSE e R^2)

Objetivos desta sessão

- Dividir um dataset em treino e teste antes de ajustar um modelo de regressão, em vez de avaliar sobre os mesmos dados usados no ajuste.
- Ajustar uma regressão linear simples com scikit-learn e interpretar o intercepto e o coeficiente angular.
- Calcular resíduos (y real – y previsto) e reconhecer o que um resíduo positivo ou negativo significa.
- Calcular MAE, RMSE e R^2 sobre dados de teste, e explicar o que cada métrica mede e como elas se relacionam entre si.
- Usar um gráfico de resíduos para diagnosticar se uma reta é uma escolha razoável para os dados.

1. Retomada: da prévia à avaliação formal

Na anterior formulamos quatro modelos de regressão linear simples, múltipla, polinomial e SVR e comparamos um R^2 de cada um, mas calculado sobre os MESMOS dados usados no ajuste, só como prévia. Isso tende a favorecer o modelo: ele é avaliado exatamente onde aprendeu. Hoje fechamos essa lacuna, com foco só na regressão linear simples: separar treino e teste corretamente, examinar os resíduos e calcular MAE, RMSE e R^2 formalmente, sobre anúncios que o modelo nunca viu.

O dataset continua o mesmo da Aula 6 alugueis_tratado.csv, 1000 anúncios de aluguel já tratados (sem valores ausentes, sem colunas categóricas):

	area_m2	quartos	distancia_km	valor_aluguel
0	82.6	3	3.50	2246.05
1	49.0	3	13.05	1128.66
2	93.8	3	1.29	2537.33
3	98.5	4	23.32	2113.33
4	28.0	1	13.07	927.63

2. Por que separar treino e teste

Se o modelo é ajustado e avaliado nos mesmos dados, ele pode parecer melhor do que realmente é em parte porque memorizou particularidades daqueles exemplos específicos, não porque aprendeu um padrão que generaliza. Separando uma fatia dos dados ANTES de treinar, e usando essa fatia só para avaliar, a métrica final estima o que aconteceria com anúncios novos, nunca vistos:

```
X_treino, X_teste, y_treino, y_teste = train_test_split(
    X, y, test_size=0.30, random_state=42
)
# treino: 700 anúncios   teste: 300 anúncios
```

3. Ajustando a regressão linear simples

Ajustando `LinearRegression()` só no treino, usando `area_m2` como único atributo:

```
y_previsto = 54.46 + 17.37 * area_m2
```

Como ler b_0 e b_1

$b_1 = 17,37$: cada m^2 a mais no imóvel está associado a +R\$ 17,37 no aluguel previsto, mantendo tudo o mais constante.

$b_0 = 54,46$: valor previsto para `area_m2 = 0` fora da faixa real dos dados (o menor imóvel do dataset tem $28 m^2$). Serve só para posicionar a reta, não deve ser interpretado ao pé da letra como um "aluguel mínimo".

4. Resíduos: o que sobrou depois do modelo

O resíduo de um exemplo é a diferença entre o valor real e o valor previsto: $\text{resíduo} = y_{\text{real}} - y_{\text{previsto}}$. Um resíduo positivo significa que o imóvel alugou por MAIS do que o modelo previu; negativo, por MENOS. Nos primeiros anúncios do conjunto de teste:

area_m2	y_real	y_previsto	residuo
105.1	1668.45	1881.11	-212.66
62.3	1240.30	1136.68	103.62
88.7	1523.90	1595.61	-71.71
...	...	...	...

O resíduo médio no teste ficou em torno de $-32,92$ próximo de zero, como se espera em qualquer regressão ajustada por mínimos quadrados: o modelo não erra sistematicamente para cima nem para baixo. Mas isso não diz nada sobre o TAMANHO típico de cada erro individual os resíduos variaram de $-689,62$ a $+609,79$ nesse conjunto de teste. É para medir esse tamanho típico que servem as métricas da próxima seção.

5. Métricas de erro: MAE, RMSE e R^2

Sobre o mesmo conjunto de teste (300 anúncios nunca vistos no treino):

MAE (erro absoluto médio)	= R\$ 172,90
RMSE (raiz do erro quadrático médio)	= R\$ 217,49
R^2 (variação explicada)	= 0,7707

MAE: em média, a previsão erra R\$ 172,90 para mais ou para menos todo erro pesa na mesma proporção do seu tamanho (é a média do valor absoluto de cada resíduo).

RMSE é sempre maior ou igual ao MAE, porque eleva cada erro ao quadrado antes de tirar a média e só depois tira a raiz erros grandes pesam desproporcionalmente mais. Aqui, $\text{RMSE} - \text{MAE} = \text{R\$ } 44,59$: quanto maior essa diferença, mais a distribuição de erros tem alguns poucos casos bem piores que a média (o próprio resíduo máximo, R\$ 609,79, já é candidato a um desses casos).

$R^2 = 0,7707$: a área sozinha explica cerca de 77% da variação do valor do aluguel no conjunto de teste. O restante vem de quartos, distancia_km e de ruído que uma única variável não consegue capturar o motivo pelo qual a Aula 6 também apresentou a regressão múltipla.

6. Visualizando o ajuste e os resíduos

A Figura 1 mostra dois painéis lado a lado: à esquerda, a reta ajustada (só no treino) sobre os dados de teste; à direita, os resíduos contra o valor previsto.




Figura 1 regressão linear simples de valor_aluguel sobre area_m2: reta ajustada (esquerda) e resíduos x valor previsto (direita), sobre os 300 anúncios de teste.

Se o modelo estivesse bem especificado, a nuvem de pontos da direita estaria espalhada aleatoriamente ao redor da linha resíduo = 0, sem formar uma curva. É basicamente o que se observa aqui os resíduos não seguem uma curva sistemática clara, embora fiquem mais dispersos nos valores previstos intermediários. Uma curva sistemática (resíduos positivos nas pontas e negativos no meio, ou o contrário) seria sinal de que a relação real não é uma reta o caso que a regressão polinomial, vista na Aula 6, foi construída para tratar.

Um cuidado importante

MAE e RMSE têm a mesma unidade do alvo (aqui, reais) e por isso são mais fáceis de explicar a um público não técnico do que R^2 , que é adimensional. Quando for comparar dois modelos, prefira olhar as três métricas juntas: R^2 alto com RMSE muito maior que o MAE ainda pode esconder alguns erros grandes específicos que valem a pena investigar.

O que guardar desta sessão

- Treino e teste devem ser separados ANTES de ajustar o modelo avaliar nos mesmos dados do treino superestima a qualidade do ajuste.
- Em $y = b_0 + b_1x$, b_1 é a variação prevista no alvo por unidade do atributo; b_0 só tem sentido interpretável se $x = 0$ estiver dentro da faixa real dos dados.
- Resíduo = y real – y previsto. Resíduo médio perto de zero é esperado por construção (mínimos quadrados) e não substitui olhar o tamanho típico dos erros.
- MAE e RMSE têm a unidade do alvo; $RMSE \geq MAE$ sempre, e a diferença entre os dois cresce quando existem erros grandes específicos. R^2 mede a fração da variação do alvo explicada pelo modelo.
- Um gráfico de resíduos sem padrão sistemático é evidência de que a reta é uma escolha razoável; uma curva no gráfico sugere que a relação real não é linear.