





A Cartografia dos Dados


Traduzindo algoritmos de classificação
em geometria visual.

Aprendizado de Máquina • Modelos Preditivos e Fronteiras de Decisão



Resumo: o que define o tipo de problema é o que você quer prever (o target y).
Os algoritmos são diferentes formas de aprender essa relação.


Fechando o Ciclo: Prever Números vs. Separar Espaços



REGRESSÃO

O alvo é numérico.

A grande pergunta: A ordem importa? Sim. Um valor maior tem hierarquia sobre um menor. O objetivo é traçar uma trajetória matemática contínua.



CLASSIFICAÇÃO

O alvo é categórico.

A grande pergunta: A ordem importa? Não. 'Aprovado' não é matematicamente maior que 'Reprovado'. São apenas rótulos. O objetivo é demarcar territórios e fronteiras.

A Protagonista: A Fronteira de Decisão

Um classificador não prevê apenas pontos isolados. Ele divide o espaço inteiro.




O QUE É?

A linha (ou superfície hiperdimensional) onde a decisão do modelo muda abruptamente.
De um lado, Classe 0. Do outro, Classe 1.

POR QUE IMPORTA?


A partir de agora, não olharemos para o código.
Focaremos em duas perguntas:
(1) Qual a ideia central?
e (2) Qual o FORMATO da fronteira que ele desenha?

k-NN (k-Nearest Neighbors): O Memorizador



COMO PENSA: A IDEIA CENTRAL


Votação por vizinhança. O modelo não "aprende" uma regra geral; ele apenas memoriza os dados (método lazy). Para prever, olha os vizinhos mais próximos e adota a classe da maioria.



COMO DESENHA: O FORMATO


Irregular e reativo.
Uma fronteira cheia de recortes que acompanha cada ponto de treino de perto.
Quanto menor o k , mais fragmentado fica o mapa.

Regressão Logística: O Squeeze Linear



COMO PENSA: A IDEIA CENTRAL


Probabilidade linear. Calcula uma combinação linear dos atributos e passa o resultado por uma função sigmoide, "espremendo" o valor entre 0 e 1. Se a probabilidade for maior que 0.5, prevemos a classe 1.



COMO DESENHA: O FORMATO


Uma reta absoluta. Como o corte ocorre em uma equação linear matemática, a fronteira será sempre uma linha reta inquebrável. Simples e interpretável, mas altamente inflexível.

Árvores de Decisão: O Fatiador Ortogonal



COMO PENSA: A IDEIA CENTRAL


Splits sucessivos por pureza. Uma sequência de perguntas baseadas em um único atributo por vez. O modelo busca o corte que crie os grupos menos misturados possíveis.



COMO DESENHA: O FORMATO


Uma escadinha de retângulos. Como cada pergunta corta o espaço perpendicularmente a um eixo (ex: $x > 5$), a fronteira final nunca será uma curva suave ou uma diagonal autêntica.

Random Forest: A Sabedoria da Multidão



COMO PENSA: A IDEIA CENTRAL


Votação em comitê. Treina centenas de árvores diferentes (cada uma vendo uma amostra ligeiramente diferente dos dados) e faz com que todas votem para decidir a classe final.



COMO DESENHA: O FORMATO


Combate ao *overfitting*. Erros individuais de árvores distintas se cancelam. A fronteira final preserva a lógica ortogonal, mas torna-se exponencialmente mais suave e estável do que uma árvore isolada.

Naive Bayes: O Probabilista Ingênuo



COMO PENSA: A IDEIA CENTRAL


Teorema de Bayes + Gaussianas. Estima a probabilidade modelando cada atributo como uma curva de sino. É “ingênuo” porque assume, de forma irreal, que os atributos não têm relação ou influência entre si.



COMO DESENHA: O FORMATO

Curvas perfeitamente suaves. A combinação de múltiplas distribuições normais independentes gera fronteiras polidas e contínuas, sem os dentes do k-NN ou os ângulos duros das árvores.

SVM (Kernel RBF): O Maximizador de Margens



COMO PENSA: A IDEIA CENTRAL


Foco exclusivo nos extremos. O SVM busca a fronteira que deixa a maior margem de segurança possível até os pontos mais difíceis e críticos de cada classe (os Vetores de Suporte).



COMO DESENHA: O FORMATO

Um elástico hiper-flexível. Ao usar o Kernel RBF, o modelo projeta os dados em alta dimensionalidade. O resultado é uma curva incrivelmente adaptável, ideal para topografias complexas.


0 Desafio: 0 Labirinto das Duas Luas



O TERRENO DE TESTES

Para revelar o caráter oculto de cada algoritmo, introduzimos um dataset sintético: Make Moons. Duas luas entrelaçadas formam um quebra-cabeça geométrico deliberado. Por que o usamos? Porque a separação destas classes é topograficamente impossível de ser feita por uma única linha reta. É o ambiente perfeito para expor os limites estruturais do nosso arsenal.

1 Dataset, 5 Realidades Geométricas




A MATEMÁTICA DITA A FORMA


Os mesmos 210 pontos de treino originais. Cinco fronteiras de decisão completamente diferentes, ditadas exclusivamente pelas leis geométricas e matemáticas de seus respectivos criadores.

Anatomia de uma Divergência: O Ponto de Contenção

O Perigo Oculto da Acurácia Global



Árvore de Decisão




SVM

Se olharmos apenas para o desempenho global, muitos destes modelos possuem acurácias idênticas. Mas observe este ponto específico. A Árvore o classifica como 0 devido ao seu corte retangular cego, enquanto o SVM o prevê como 1 devido à sua curvatura adaptativa. Modelos com acurácia idêntica discordam profundamente nas margens.

O Mapa da Escolha: Matriz de Diagnóstico

 FAMÍLIA	 MECANISMO CENTRAL	 GEOMETRIA DA FRONTEIRA	 MELHOR CASO DE USO
k-NN	Votação por Proximidade	Irregular e com dentes	Mapeamento de fronteiras altamente fragmentadas.
Regressão Logística	Equação + Sigmoides	Linha reta / Hiperplano	Classes linearmente separáveis; necessidade de interpretação.
Árvores / Random Forest	Cortes sucessivos de pureza	Escadinha ortogonal	Interações complexas de variáveis; regras lógicas claras.
Naive Bayes	Teorema de Bayes	Curvas polidas e orgânicas	Baseline rápido; altamente eficaz mesmo com premissas falhas.
SVM (Kernel RBF)	Maximização de Margem	Curva elástica e adaptável	Topografias de dados espaciais altamente complexas e não-lineares.

Sintetizando a Cartografia



A GEOMETRIA GOVERNA

A matemática por trás do código dita a forma.

Retas não podem dobrar, árvores não podem fazer diagonais. Conhecer a ferramenta é conhecer sua limitação espacial.



ALÉM DA ACURÁCIA

Fronteiras diferentes surgem do mesmo dataset.

Confiar apenas em métricas globais esconde as discordâncias vitais que ocorrem nas bordas das suas decisões.



PRÓXIMOS PASSOS (SEMANA 8)

Nenhuma família é soberana de forma absoluta.

A seguir, abandonaremos as formas sintéticas e aplicaremos este arsenal aos dados reais e ruidosos de empréstimos, usando Validação Cruzada.