



[Aprendizado de Máquina]

5 Algoritmos, 1 Problema Real.

Um laboratório comparativo
de classificação sobre
solicitações de crédito.

Os Dados: Solicitações de Empréstimo

450 registros

5 atributos: idade, renda, tempo_emprego, score_credito, cidade



52% Negados

48% Aprovados

As Regras do Jogo


Em uma comparação justa, apenas o algoritmo muda. Tudo o mais é constante:

- ✓ Mesmos dados e divisão (30% teste, estratificado).
- ✓ Mesmo pré-processamento (aprendido só no treino).
- ✓ Mesmas métricas no mesmo conjunto de teste.



Se cada modelo recebesse um tratamento diferente, não saberíamos dizer se a diferença vem do algoritmo ou da preparação.

O "Piso" da Competição (Baseline)




Block 1

O baseline é um modelo que não aprende nada: ele apenas 'chuta' a classe mais comum dos dados de treino. Neste caso, 52% dos pedidos são negados.



Se o seu modelo de Machine Learning não supera 51,9% de acurácia com folga, ele não aprendeu absolutamente nada útil. Comemorar acurácia sem conhecer o baseline é um erro crítico.

A Barreira contra o Vazamento de Dados



Por que usar um Pipeline e um ColumnTransformer?

Se a média ou o desvio-padrão usarem os dados de teste durante o cálculo, informações do futuro “vazam” para o modelo, invalidando a avaliação.


Regra de Ouro

A preparação é calculada exclusivamente **no treino** e apenas aplicada no teste.

Os 5 Competidores

Algoritmo	Ideia Central	Fronteira Típica	Sensível à Escala?
k-NN	Vota a maioria dos k vizinhos (k=5)		Sim (usa distância)
Regressão Logística	Combinação linear em probabilidade		Pouco
Árvore de Decisão	Perguntas de corte sucessivas		Não
Naive Bayes Gaussiano	Teorema de Bayes (atributos independentes)		Não
SVM (kernel='rbf')	Maior margem possível		Sim (usa distância)

Round 1: Acurácia Bruta



Todos os modelos superam o baseline com folga, confirmando que há sinal nos dados. Regressão Logística e SVM lideram empatados com 85,9%.

Mas cuidado: com apenas 135 exemplos no conjunto de teste, cada exemplo vale cerca de 0,7%. Uma diferença de 1 ou 2 pontos percentuais pode ser mero acaso do sorteio. A acurácia não conta a história toda.

Além da Acurácia: O Custo Real do Erro


Matriz de Impacto nos Negócios

Verdadeiro Positivo




Bom pagador aprovado.

Falso Positivo



Aprovação Indevida:
Cliente recebe e não paga.
Risco de calote (Custo Alto)

Falso Negativo



Negação Indevida:
Bom pagador rejeitado.
Perda de oportunidade (Custo Médio)

Verdadeiro Negativo



Mau pagador rejeitado.

Em concessão de crédito, os erros não têm pesos iguais. Aprovar um mau pagador costuma custar muito mais para o banco do que negar crédito a um bom cliente. Precisamos olhar o detalhe de como os modelos erram, não apenas quanto eles erram.

Radiografia dos Erros: Precisão e Recall

Dois modelos com acurácia similar podem ter perfis de risco completamente diferentes na prática.

Naive Bayes

16 Aprovações Indevidas
(Falsos Positivos)

Um métric acnsmanilidade internez::ue aprovações indevidas. Falsos positivos), o tio-ea contés data éc-peoesia crepandatrada e muincados e e a merçio mais calotes.

 Naive Bayes

Regressão Logística

10 Aprovações Indevidas
(Falsos Positivos)

Um métric consurtilidade internez::ue aprovações indevidas. Falsos positivos), siña arvoutes dara airoter podenas :respostrada o muincados e o murto mais calotes.

 Logistic Regression


O Naive Bayes cometeu **60% mais aprovações indevidas** que a Regressão Logística. Em um cenário real, isso significa muito mais calotes.

DEFINIÇÕES

Precisão: Dos que o modelo aprovou, quantos eram realmente bons pagadores?

Recall: Dos que eram bons pagadores, quantos o modelo conseguiu aprovar?

A Armadilha da Escala (Round 2)



Repetimos o experimento removendo a padronização dos atributos numéricos.

O desempenho da Árvore e da Regressão Logística continuou o mesmo.

Mas o SVM despencou, perdendo mais de 25 pontos de acurácia.

O que aconteceu?

Por que a Escala casa Destrói Alguns Modelos?

0 Efeito da Distância



A Lógica da Árvore

Renda > 5000?
-> Sim/Não




A árvore apenas corta; a escala absoluta não importa.

k-NN e SVM dependem de cálculos de distância geométrica entre os pontos. Sem padroniz, a Renda (na casa dos milhares) domina completamente a Idade (na casa de dezenas). O algoritmo passa a ignorar as outras variáveis.

Regra prática: Padronize os dados sempre que usar k-NN ou SVM.

O Risco da Memorização (Overfitting)




Com hiperparâmetros que dão flexibilidade extrema (como `k=1` no k-NN ou `profundidade infinita` na Árvore), o modelo atinge 100% de acerto no treino.

Modelos flexíveis demais apenas "decoram" o treino e memorizam ruído, falhando miseravelmente em dados reais.

Aviso: Escolher hiperparâmetros olhando a métrica do teste é trapaça!

A Ilusão do Sorteio Único (Round 3)

Distribuição de Acurácia em 10 Sorteios Aleatórios




Repetimos o experimento inteiro 10 vezes, mudando apenas a semente do sorteio dos dados.

O cenário virou um caos: a Regressão Logística venceu 5 vezes, o SVM venceu 3 vezes e a Árvore de Decisão venceu 2 vezes.

As faixas de desempenho se sobrepõem muito. Uma única divisão de treino/teste é ruidosa demais para declarar um vencedor absoluto.

Síntese: Qual é o Melhor Modelo?



Não existe "o melhor modelo" de forma absoluta. A resposta responsável para a escolha de um algoritmo de ML depende inteiramente de como você mede o sucesso e de evidenciar a incerteza estatística das medições.

**O vencedor empírico de um único sorteio hoje pode
perfeitamente ser o perdedor de amanhã.**

O Checklist do Avaliador de Modelos

O que levar da arena para a vida real:

☐ **O Baseline:** O modelo supera com folga o chute mais frequente trivial?

☐ **Blindagem contra Vazamento:** Todo o pré-processamento está confinado num Pipeline aprendido só no treino?

☐ **Custo do Erro:** Você parou de olhar só para a acurácia e analisou o custo real de Falsos Positivos vs Negativos?

☐ **Escala:** Algoritmos sensíveis à distância (k-NN, SVM) receberam dados padronizados?

☐ **Incerteza Testada:** Você validou com múltiplos sorteios antes de declarar a vitória de um modelo?

