

Avaliação Prática 2

Aprendizado supervisionado: regressão polinomial e K-NN — preparação de dados, validação e vazamento

Instruções

- Prova individual, a ser resolvida em Python (pandas e scikit-learn). Entregue o notebook (.ipynb) executado de ponta a ponta, com as respostas escritas dos itens que pedem justificativa em células de texto.
- Estão disponíveis dois arquivos: `estufas_energia.csv` (Exercício 1) e `lotes_cafe.csv` (Exercício 2). Escolher as colunas e justificar as decisões faz parte da avaliação.
- Sempre que houver sorteio ou embaralhamento, use `random_state=42`. Em cada exercício, as duas colunas de entrada devem ser padronizadas com `StandardScaler` antes da execução do algoritmo.
- Decisões sem justificativa valem no máximo metade da pontuação do item. Resultados numéricos devem ser apresentados no notebook, não apenas descritos.

Distribuição: Exercício 1 = 4,0 pontos; Exercício 2 = 4,0 pontos; Questão 3 (discursiva) = 2,0 pontos. Total: 10,0.

Exercício 1 (4,0 pontos) — Regressão polinomial

Uma empresa de hortifrúti mantém estufas climatizadas e quer prever o consumo diário de energia de cada estufa (aquecimento no frio e refrigeração no calor) a partir da previsão do tempo para o dia seguinte, para contratar a demanda de energia com antecedência. Ela reuniu 150 dias de operação no arquivo `estufas_energia.csv`, com as colunas:

Coluna	Descrição
<code>id_estufa</code>	Identificador do registro
<code>temperatura_externa_c</code>	Temperatura média externa do dia (°C)
<code>umidade_relativa_pct</code>	Umidade relativa média do ar externo (%)
<code>custo_energia_rs_dia</code>	Custo da energia consumida no dia (R\$), calculado ao final do dia com base na leitura do medidor
<code>consumo_kwh_dia</code>	Consumo de energia da estufa no dia (kWh)

Tarefas:

- Identifique o tipo de problema (supervisionado ou não, e a natureza da variável a prever) e escolha o algoritmo que utilizará, justificando a escolha com base no que se espera da relação entre temperatura e consumo. **[0,5]**
- Defina quais colunas serão usadas como entradas do modelo e qual será a saída. Justifique a utilização ou a exclusão de cada coluna da tabela acima, tendo em mente o momento em que a previsão será feita. **[0,5]**
- Padronize as colunas `temperatura_externa_c` e `umidade_relativa_pct` com `StandardScaler`. Explique em que momento o `StandardScaler` deve ser ajustado (fit) em relação à divisão dos dados da validação e por quê, e indique em que ponto da sequência de etapas (padronização, geração dos termos polinomiais, regressão) ele deve ficar. **[0,5]**
- Com validação cruzada de 5 partições (embaralhadas, `random_state=42`), teste os graus de 1 a 8. Apresente, para cada grau, o RMSE médio de treino e o RMSE médio de validação. Escolha o grau e justifique a escolha, indicando quais graus apresentam subajuste e quais apresentam sobreajuste. **[1,0]**
- Para o grau escolhido, apresente RMSE, MAE e R^2 em cada partição, a média e o desvio-padrão, e interprete o resultado. **[0,5]**

f) Treine o modelo final com todos os dados e estime o consumo (kWh/dia) das três estufas descritas abaixo, com a previsão do tempo para os próximos dias. [1,0]

Estufa	temperatura_externa_c (prevista)	umidade_relativa_pct (prevista)
A	8	70
B	21	55
C	35	85

Exercício 2 (4,0 pontos) — K-NN

Uma cooperativa cafeeira quer classificar a bebida de cada lote recebido (fina, regular ou rio) já na chegada, usando apenas informações da fazenda, antes da prova de xicara que será feita por degustadores. Ela reuniu 300 lotes já classificados no arquivo `lotes_cafe.csv`, com as colunas:

Coluna	Descrição
<code>id_lote</code>	Identificador do lote
<code>altitude_m</code>	Altitude da lavoura de origem (m)
<code>umidade_grao_pct</code>	Umidade do grão na recepção (%)
<code>preco_saca_rs</code>	Preço pago pela saca (R\$), definido pela cooperativa depois da classificação da bebida
<code>classe_bebida</code>	Classe da bebida: fina, regular ou rio

Tarefas:

a) Identifique o tipo de problema (supervisionado ou não, e a natureza da variável a prever) e escolha o algoritmo que utilizará, justificando a escolha. [0,5]

b) Defina quais colunas serão usadas como entradas do modelo e qual será a saída. Justifique a utilização ou a exclusão de cada coluna da tabela acima, tendo em mente o momento em que a classificação será feita. [0,5]

c) Padronize as colunas `altitude_m` e `umidade_grao_pct` com `StandardScaler`. Justifique por que a padronização é necessária para este algoritmo, citando a ordem de grandeza das duas colunas, e explique em que momento o `StandardScaler` deve ser ajustado em relação à validação. [0,5]

d) Com validação cruzada estratificada de 5 partições (embaralhadas, `random_state=42`), teste os valores de K ímpares de 1 a 25. Apresente, para cada K, a acurácia média de treino e de validação. Escolha o valor de K e justifique, explicando o que ocorre com K = 1. [1,0]

e) Para o K escolhido, apresente a acurácia e o F1 macro em cada partição, a média e o desvio-padrão, e a matriz de confusão obtida com as previsões da validação cruzada. Interprete o resultado. [0,5]

f) Treine o modelo final com todos os lotes e classifique os três lotes novos abaixo. [1,0]

Lote	altitude_m	umidade_grao_pct
X	1000	12,0
Y	1350	12,4
Z	1250	11,0

Questão 3 (discursiva — 2,0 pontos)

Sobre os dois algoritmos desta prova e sobre a escolha de hiperparâmetros: (1) explique como o valor de K no K-NN e o grau na regressão polinomial controlam a complexidade do modelo, relacionando valores extremos de cada um com subajuste e sobreajuste; (2) explique por que K e o grau não devem ser escolhidos pelo desempenho no conjunto de treino e como escolhê-los de forma adequada; (3) cite uma limitação do K-NN e uma limitação da regressão polinomial ao fazer previsões para dados novos. Dê, ainda, um exemplo de situação em que a regressão polinomial seria preferível à regressão linear simples. Responda em até 15 linhas.