

Avaliação Prática Duas Bases de Dados

Aprendizado supervisionado e não supervisionado, regressão: preparação de dados, validação e vazamento

Aluno(a): _____ Prontuário: _____

Instruções

- Prova individual, a ser resolvida em Python (pandas e scikit-learn). Entregue o notebook (.ipynb) executado de ponta a ponta, com as respostas escritas dos itens que pedem justificativa em células de texto.
- Estão disponíveis dois arquivos: talhoes_soja.csv (Exercício 1) e linhas_onibus.csv (Exercício 2). Escolher o algoritmo adequado ao problema, e justificar, faz parte da avaliação.
- Sempre que houver sorteio, use random_state=42. Em cada exercício, duas colunas devem ser padronizadas com StandardScaler antes da execução do algoritmo.
- Decisões sem justificativa valem no máximo metade da pontuação do item. Resultados numéricos devem ser apresentados no notebook, não apenas descritos.

Distribuição: Exercício 1 = 4,0 pontos; Exercício 2 = 4,0 pontos; Questão 3 (discursiva) = 2,0 pontos. Total: 10,0.

Exercício 1 (4,0 pontos)

Uma cooperativa agrícola quer estimar a produtividade de um talhão de soja antes do plantio, para planejar a compra de insumos e a contratação de armazenagem. Ela reuniu o histórico de 400 talhões de safras já encerradas no arquivo talhoes_soja.csv, com as colunas:

Coluna	Descrição
id_talhao	Identificador do talhão
area_ha	Área do talhão (hectares)
chuva_mm	Chuva acumulada durante o ciclo da cultura (mm)
ph_solo	pH do solo medido antes do plantio
adubo_kg_ha	Adubo aplicado (kg por hectare)
receita_bruta_rs_ha	Receita bruta obtida com a colheita (R\$ por hectare)
produtividade_sacas_ha	Produtividade colhida (sacas por hectare)

Tarefas:

- Identifique o tipo de problema (supervisionado ou não, e a natureza da variável a prever) e escolha o algoritmo que utilizará, justificando a escolha. [0,5]
- Defina quais colunas serão usadas como entradas do modelo e qual será a saída. Justifique a utilização ou a exclusão de cada coluna da tabela acima, tendo em mente o momento em que a previsão será feita. [0,5]
- Padronize as colunas chuva_mm e adubo_kg_ha com StandardScaler antes do treinamento (as demais colunas de entrada não devem ser padronizadas). Explique em que momento o StandardScaler deve ser ajustado (fit) em relação à divisão dos dados da validação e por quê. [1,0]

- d) Avalie o modelo com validação cruzada de 5 partições (embaralhadas, `random_state=42`). Escolha e justifique as métricas de desempenho adequadas ao tipo de problema; apresente o valor de cada métrica em cada partição, a média e o desvio-padrão, e interprete o resultado. [1,0]
- e) Treine o modelo final com todos os dados e estime a produtividade (sacas por hectare) dos três talhões que serão plantados na próxima safra, descritos abaixo. [1,0]

Talhão	area_ha	chuva_mm (prevista)	ph_solo	adubo_kg_ha
A	100	1.000	5,5	200
B	300	1.050	6,0	220
C	500	1.100	6,5	240

Exercício 2 (4,0 pontos)

A prefeitura de uma cidade quer conhecer os perfis de operação das linhas de ônibus urbanas para decidir onde investir em frota e em corredores exclusivos. Não existe nenhuma classificação prévia das linhas. O arquivo `linhas_onibus.csv` traz 240 linhas, com as colunas:

Coluna	Descrição
<code>id_linha</code>	Identificador da linha
<code>passageiros_dia</code>	Média de passageiros transportados por dia útil
<code>atraso_medio_min</code>	Atraso médio nos horários de saída (minutos)

Tarefas:

- a) Identifique o tipo de problema e escolha o algoritmo que utilizará, justificando a escolha. [0,5]
- b) Indique quais colunas entram no algoritmo e justifique. [0,5]
- c) Padronize as colunas `passageiros_dia` e `atraso_medio_min` com `StandardScaler` antes de executar o algoritmo. Justifique por que a padronização é necessária nesta base, citando a ordem de grandeza das duas colunas. [1,0]
- d) Se o algoritmo escolhido exigir definir previamente o número de grupos, determine-o testando valores de 2 a 8 (`random_state=42`), com critérios quantitativos de sua escolha. Apresente os valores obtidos para cada número testado e justifique a decisão. [1,0]
- e) Com o número de grupos escolhido, apresente o tamanho de cada grupo e o seu perfil típico na escala original das variáveis (em passageiros por dia e em minutos), e dê um nome a cada perfil. [0,5]
- f) A prefeitura vai criar três linhas novas, com a demanda e o atraso estimados abaixo. Indique a que grupo cada uma pertence. [0,5]

Linha	passageiros_dia	atraso_medio_min
X	700	2,5
Y	1.100	4,0
Z	950	3,0

Questão 3 (discursiva — 2,0 pontos)

Sobre a aula de avaliação de modelos (subajuste e sobreajuste): defina subajuste (underfitting) e sobreajuste (overfitting); explique como é possível diagnosticar cada um comparando o erro de treino com o erro de validação à medida que a complexidade do modelo aumenta (descreva o comportamento esperado das duas curvas); e cite duas ações práticas que ajudam a corrigir cada um dos dois problemas. Dê um exemplo de hiperparâmetro que controla a complexidade de um modelo visto em aula. Responda em até 15 linhas.